

6주차 예습과제_김유진

[5장] 회귀

01 회귀 소개

회귀 분석: 데이터 값이 평균과 같은 일정한 값으로 돌아가려는 경향을 이용한 통계학 기법

핵심: 주어진 피처와 결정값 데이터 기반에서 학습을 통해 최적의 회귀 계수를 찾아내는 것

지도 학습: 분류(예측값이 카테고리화 같은 이산형 클래스 값) / 회귀(연속형 숫자 값)

선형 회귀: 실제 값과 예측값의 차이(오류의 제곱 값)를 최소화하는 직선형 회귀선을 최적화하는 방식

<대표적인 선형 회귀 모델>


- 일반 선형 회귀
- 릿지
- 라쏘
- 엘라스틱넷
- 로지스틱 회귀

02 단순 선형 회귀를 통한 회귀 이해

단순 선형 회귀: 독립/종속 변수 모두 하나

최적의 회귀 모델을 만든다 (RSS)

머신러닝 회귀 알고리즘은 데이터를 계속 학습하면서 이 비용 함수가 반환하는 값(즉, 오류 값)을 지속해서 감소시키고 최종적으로는 더이상 감소하지 않는 최소의 오류 값을 구하는 것




$$RSS(w_0, w_1) = \frac{1}{N} \sum_{i=1}^N (y_i - (w_0 + w_1 * x_i))^2$$

(i 는 1부터 학습 데이터의 총 건수 N 까지)

03 비용 최소화하기 - 경사하강법 소개

경사하강법의 핵심: 어떻게 하면 오류가 작아지는 방향으로 W 값을 보정할 수 있을까



$$\frac{\partial R(w)}{\partial w_1} = \frac{2}{N} \sum_{i=1}^N -x_i * (y_i - (w_0 + w_1 x_i)) = -\frac{2}{N} \sum_{i=1}^N x_i * (\text{실제값}_i - \text{예측값}_i)$$

$$\frac{\partial R(w)}{\partial w_0} = \frac{2}{N} \sum_{i=1}^N -(y_i - (w_0 + w_1 x_i)) = -\frac{2}{N} \sum_{i=1}^N (\text{실제값}_i - \text{예측값}_i)$$

비용함수가 최소가 되는 지점을 찾는 방식

- Step 1: w_1, w_0 를 임의의 값으로 설정하고 첫 비용 함수의 값을 계산합니다.
- Step 2: w_1 을 $w_1 + \eta \frac{2}{N} \sum_{i=1}^N x_i * (\text{실제값}_i - \text{예측값}_i)$, w_0 을 $w_0 + \eta \frac{2}{N} \sum_{i=1}^N (\text{실제값}_i - \text{예측값}_i)$ 으로 업데이트한 후 다시 비용 함수의 값을 계산합니다.
- Step 3: 비용 함수가 감소하는 방향으로 주어진 횟수만큼 Step 2를 반복하면서 w_1 과 w_0 를 계속 업데이트합니다.

$$\hat{Y} = X_{mat} * \begin{bmatrix} w_1 & w_2 & \dots & w_m \end{bmatrix}^T + w_0$$

* 내적

를 Weight의 배열인 W안에 포함시키기 위해서 Xmat의 맨 처음 열에 모든 데이터의 값이 1인 피쳐를 추가하겠습니다. 이제 회귀 예측값은 $\hat{Y} = X_{mat} * W^T$ 와 같이 도출할 수 있습니다.



$$\hat{Y} = X_{mat} * W^T$$

* 내적

04 사이킷런 LinearRegression을 이용한 보스턴 주택 가격 예측

LinearRegression 클래스 - Ordinary Least Squares

LinearRegression 클래스: 예측값과 실제 값의 RSS(Residual Sum of Squares)를 최소화 해 OLS 추정 방식으로 구현한 클래스

입력 파라미터	fit_intercept: 불린 값으로, 디폴트는 True입니다. Intercept(절편) 값을 계산할 것인지 말지를 지정합니다. 만일 False로 지정하면 intercept가 사용되지 않고 0으로 지정됩니다. fit_intercept=True  fit_intercept=False  normalize: 불린 값으로 디폴트는 False입니다. fit_intercept가 False인 경우에는 이 파라미터가 무시됩니다. 만일 True이면 회귀를 수행하기 전에 입력 데이터 세트를 정규화합니다.
	coef_: fit() 메서드를 수행했을 때 회귀 계수가 배열 형태로 저장하는 속성. Shape는 (Target 값 개수, 피쳐 개수). intercept_: intercept 값

회귀 평가 지표

회귀 평가 지표: 실제 값과 회귀 예측값의 차이 값을 기반으로 한 지표 중심

평가 지표	설명	수식
MAE	Mean Absolute Error(MAE)이며 실제 값과 예측값의 차이를 절댓값으로 변환해 평균한 것입니다.	$MAE = \frac{1}{n} \sum_{i=1}^n Y_i - \hat{Y}_i $
MSE	Mean Squared Error(MSE)이며 실제 값과 예측값의 차이를 제곱해 평균한 것입니다.	$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$
RMSE	MSE 값은 오류의 제곱을 구하므로 실제 오류 평균보다 더 커지는 특성이 있으므로 MSE에 루트를 씌운 것이 RMSE(Root Mean Squared Error)입니다.	$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}$
R ²	분산 기반으로 예측 성능을 평가합니다. 실제 값의 분산 대비 예측값의 분산 비율을 지표로 하며, 1에 가까울수록 예측 정확도가 높습니다.	$R^2 = \frac{\text{예측값 Variance}}{\text{실제값 Variance}}$

평가 방법	사이킷런 평가 지표 API	Scoring 함수 적용 값
MAE	metrics.mean_absolute_error	'neg_mean_absolute_error'
MSE	metrics.mean_squared_error	'neg_mean_squared_error'
RMSE	metrics.mean_squared_error를 그대로 사용하되 squared 파라미터를 False로 설정.	'neg_root_mean_squared_error'
MSLE	metrics.mean_squared_log_error	'neg_mean_squared_log_error'
R ²	metrics.r2_score	'r2'

LinearRegression을 이용해 보스턴 주택 가격 회귀 구현



- CRIM: 지역별 범죄 발생률
- ZN: 25,000평방피트를 초과하는 거주 지역의 비율
- INDUS: 비상업 지역 넓이 비율
- CHAS: 찰스강에 대한 더미 변수(강의 경계에 위치한 경우는 1, 아니면 0)
- NOX: 일산화질소 농도
- RM: 거주할 수 있는 방 개수
- AGE: 1940년 이전에 건축된 소유 주택의 비율
- DIS: 5개 주요 고용센터까지의 가중 거리
- RAD: 고속도로 접근 용이도
- TAX: 10,000달러당 재산세율
- PTRATIO: 지역의 교사와 학생 수 비율
- B: 지역의 흑인 거주 비율
- LSTAT: 하위 계층의 비율
- MEDV: 본인 소유의 주택 가격(중앙값)


05 다항 회귀와 과적합/과소적합 이해

다항 회귀를 이용한 과소적합 및 과적합 이해


다항 회귀는 피처의 직선적 관계가 아닌 복잡한 다항 관계를 모델링할 수 있음

다항식의 차수가 높아질수록 매우 복잡한 피처 간의 관계까지 모델링 가능

편향-분산 트레이드 오프




- 편향이 높으면 분산은 낮아지고(과소적합) 반대로 분산이 높으면 편향이 낮아짐(과적합)
- 편향이 너무 높으면 전체 오류 높음
- 편향을 점점 낮추면 동시에 분산이 높아지고 전체 오류도 낮아짐
- 편향을 낮추고 분산을 높이면서 전체 오류가 가장 낮아지는 '골디락스' 지점을 통과하면서 분산을 지속적으로 높이면 전체 오류 값이 오히려 증가하면서 예측 성능이 다시 저하됨



06 규제 선형 모델 - 릿지, 라쏘, 엘라스틱넷

규제 선형 모델의 개요



이렇게 회귀 계수의 크기를 제어해 과적합을 개선하려면 비용(Cost) 함수의 목표가 다음과 $RSS(W) + \alpha * \|W\|^2$ 를 최소화하는 것으로 변경될 수 있습니다.

$$\text{비용 함수 목표} = \text{Min}(RSS(W) + \alpha * \|W\|^2)$$

- α : 학습 데이터 적합 정도와 회귀 계수 값의 크기 제어를 수행하는 튜닝 파라미터
- α 가 0 또는 매우 작은 값이면 비용함수 식은 기존과 동일한 $\text{Min}(RSS(W))$ 가 됨
- W 값을 0 또는 매우 작게 만들어야 Cost가 최소화되는 비용 함수 목표를 달성할 수 있음
- α 값을 크게 하면 비용 함수는 회귀 계수 W 의 값을 작게 해 과적합 개선 가능, α 값을 작게 하면 회귀 계수 W 의 값이 커져도 어느 정도 상쇄가 가능하므로 학습데이터 적합을 더 개선할 수 있음

라쏘 회귀: W 의 절댓값에 페널티를 부여하는 L1 규제를 선형 회귀에 적용한 것

엘라스틱넷 회귀: L2 규제와 L1규제를 결합한 회귀

릿지 (Ridge)	L2 규제	- 회귀 계수 제곱의 합에 페널티 부과. - 계수 크기를 전체적으로 축소함. - 계수를 0으로 만들지는 않음. - 다중공선성(피처 간 상관관계 높음) 방어에 유리함.
라쏘 (Lasso)	L1 규제	- 회귀 계수 절댓값의 합에 페널티 부과. - 불필요한 피처의 계수를 완전히 0으로 만듦. - 자동으로 피처 선택 (Feature Selection) 수행. - 모델 해석력이 높아짐.
엘라스틱넷	L1 + L2	- L1과 L2 규제를 결합한 방식. - 라쏘의 단점(상관관계 높은 피처 중 하나만 선택) 보완. - 계수 변화의 안정성 확보 가능. - 학습 시간이 상대적으로 오래 걸림.


선형 회귀 모델을 위한 데이터 변환

1. StandardScaler 클래스를 이용해 평균이 0, 분산이 1인 표준 정규 분포를 가진 데이터 세트로 변환하거나 MinMaxScaler 클래스를 이용해 최솟값이 0이고 최댓값이 1인 값으로 정규화를 수행합니다.
2. 스케일링/정규화를 수행한 데이터 세트에 다시 다항 특성을 적용하여 변환하는 방법입니다. 보통 1번 방법을 통해 예측 성능에 향상이 없을 경우 이와 같은 방법을 적용합니다.
3. 원래 값에 log 함수를 적용하면 보다 정규 분포에 가까운 형태로 값이 분포됩니다. 이러한 변환을 로그 변환(Log Transformation)이라고 부릅니다. 로그 변환은 매우 유용한 변환이며, 실제로 선형 회귀에서는 앞에서 소개한 1, 2번 방법보다 로그 변환이 훨씬 많이 사용되는 변환 방법입니다. 왜냐하면 1번 방법의 경우 예측 성능 향상을 크게 기대하기 어려운 경우가 많으며 2번 방법의 경우 피처의 개수가 매우 많을 경우에는 다항 변환으로 생성되는 피처의 개수가 기하급수로 늘어나서 과적합의 이슈가 발생할 수 있기 때문입니다.


07 로지스틱 회귀

로지스틱 회귀: 선형 회귀 방식을 분류에 적용한 알고리즘

- 분류에 사용됨
- 선형 회귀 계열
- 가볍고 빠르며, 이진 분류 예측 성능도 뛰어남



〈 선형 회귀의 선형 함수 〉



〈 로지스틱 회귀의 시그모이드 함수 〉

08 회귀 트리

- 트리 기반의 회귀는 회귀 트리를 이용하는 것
- (=회귀를 위한 트리를 생성하고 이를 기반으로 회귀 예측을 하는 것)
- **결정 트리 알고리즘**을 회귀에 적용한 모델

차이점: 선형 회귀는 **가중치 조합**으로 최적의 직선을 찾음. / 회귀 트리는 여러 개의 구간(노드)로 나누고, 각 구간 내 데이터의 **평균값**을 예측값으로 함

알고리즘	회귀 Estimator 클래스	분류 Estimator 클래스
Decision Tree	DecisionTreeRegressor	DecisionTreeClassifier
Gradient Boosting	GradientBoostingRegressor	GradientBoostingClassifier
XGBoost	XGBRegressor	XGBClassifier
LightGBM	LGBMRegressor	LGBMClassifier


<작동 원리>

1. 데이터 분할

2. 예측값 결정

3. 예측 방식

선형 회귀는 직선으로 예측 회귀선을 표현하는 데 반해, 회귀 트리의 경우, 분할되는 데이터 지점에 따라 브랜치를 만들면서 계단형태로 회귀선을 만들



리프 노드 생성 기준에 부합하는 트리 분할이 완료됐다면 리프 노드에 소속된 데이터 값의 평균값을 구해서 최종적으로 리프 노드에 결정 값으로 할당합니다.

