10주차 예습과제

[6장] 차원 축소

01 차원 축소의 개요

차원 축소: 매우 많은 피처로 구성된 다차원 데이터 세트의 차원을 축소해 새로운 차원의 데이터 세트를 생성하는 것

- 차원 증가 → 데이터 포인트 간의 거리 기하급수적으로 증가, 신뢰도 감소

<종류>

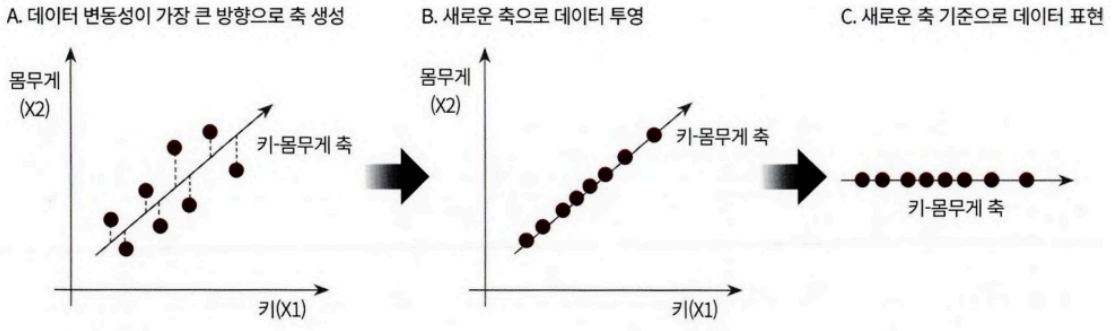
- **피처 선택**: 특정 피처에 종속성이 강한 불필요한 피처는 아예 제거하고, 데이터의 특징을 잘 나타내는 주요 피처만 선택하는 것
- **피처 추출**: 기존 피처를 단순 압축이 아닌, 피처를 함축적으로 더 잘 설명할 수 있는 또 다른 공간으로 매핑해 추출하는 것

ex) PCA, SVD, NMF

02 PCA(Principal Component Analysis

PCA 개요

- 가장 대표적인 차원 축소 기법
- 여러 변수 간에 존재하는 상관관계를 이용해 이를 대표하는 주성분을 추출해 차원을 축소하는 기법
- PCA 주성분 = 가장 높은 분산을 가지는 데이터의 축
- 원본 데이터의 피처 개수에 비해 매우 작은 주성분으로 원본 데이터의 총 변동성을 대부분 설명할 수 있는 분석법



PCA의 선형대수적 해석

- 데이터의 공분산 행렬을 고유값 분해하여, 데이터의 분산이 큰 방향을 찾는 방법이다.
- 고유 벡터는 주성분의 방향을, 고유값은 해당 방향으로의 데이터 분산을 나타낸다.
- 고유값이 큰 주성분부터 선택하고 데이터를 그 방향으로 투영하여 차원을 축소한다.

선형 변환

- 벡터에 행렬을 곱해 새로운 벡터로 변환하는 것이다.
- PCA에서는 주성분 방향을 새로운 좌표축으로 삼아 데이터의 좌표를 변환한다.

공분산과 공분산 행렬

- **분산**: 한 변수가 얼마나 흩어져 있는지 나타낸다.
- **공분산**: 두 변수가 함께 변하는 경향을 나타낸다.
  - 양수: 같은 방향으로 변하는 경향
  - 음수: 반대 방향으로 변하는 경향
- **공분산 행렬**: 대각 원소는 각 변수의 분산, 나머지 원소는 변수 쌍의 공분산인 대칭행렬이다.

고유벡터와 고유값

- **고유벡터** : 행렬을 곱해도 같은 직선 위에 남는 0이 아닌 벡터
- **고유값** : 고유벡터에 행렬이 작용할 때의 배율
- **PCA에서 고유값은 해당 주성분 방향의 분산**이며, 고유벡터는 보통 길이를 1로 맞춘다.

$$C = P \sum P^T$$

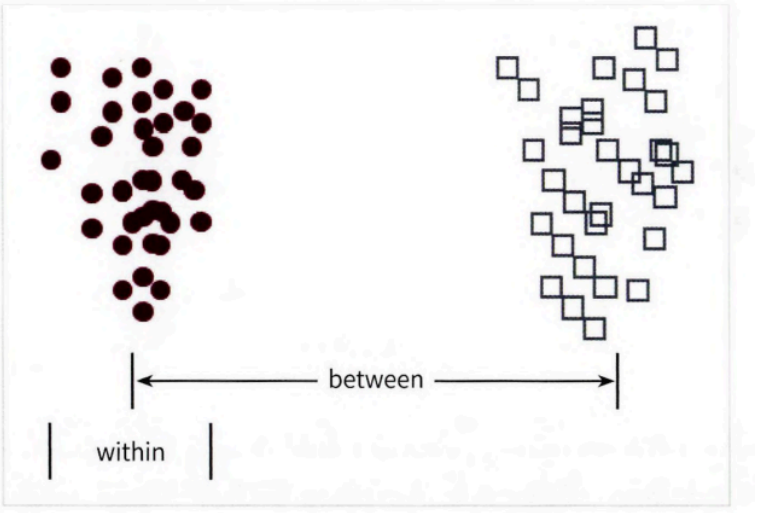
PCA 구하는 스텝

1. 입력 데이터 세트의 공분산 행렬을 생성
2. 공분산 행렬의 고유벡터와 고유값을 계산
3. 고유값이 가장 큰 순으로 K개(PCA 변환 차수만큼)만큼 고유벡터를 추출
4. 고유값이 가장 큰 순으로 추출된 고유벡터를 이용해 새롭게 입력 데이터를 변환

03 LDA

LDA 개요

- PCA와 매우 유사
- 개별 클래스를 분별할 수 있는 기준을 최대한 유지하면서 차원 축소
- 클래스 간 분산, 클래스 내부 분산의 비율을 최대화하는 방식으로 차원 축소



LDA 구하는 스텝

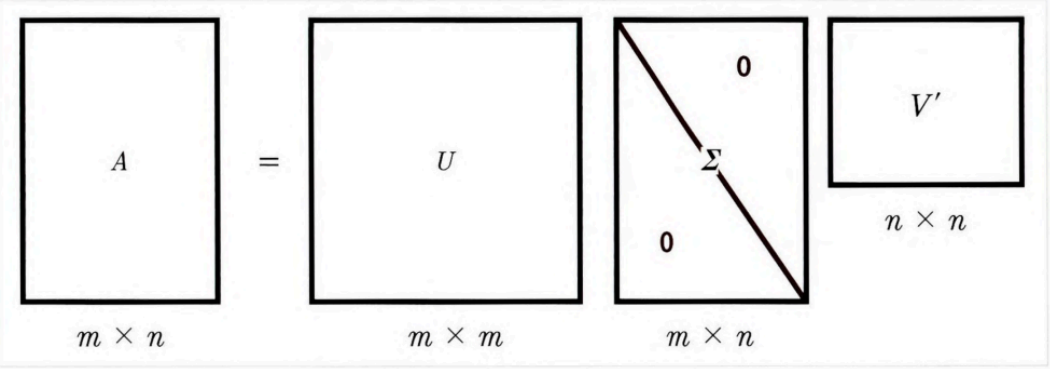
1. 클래스 내부와 클래스 간 분산 행렬을 구합니다. 이 두개의 행렬은 입력 데이터의 결정 값 클래스별로 개별 피처의 평균 벡터를 기반으로 구합니다
2. 클래스 내부 분산 행렬을 고유벡터로 분해합니다
3. 고유값이 가장 큰 순으로 K개 추출합니다.
4. 고유값이 가장 큰 순으로 추출된 고유벡터를 이용해 새롭게 입력 데이터를 변환합니다

04 SVD

SVD 개요

- PCA와 유사한 행렬 분해 기법 사용
- PCA: 정방행렬만 고유벡터로 분해 가능 / SVD는 정방행렬뿐만 아니라 행과 열의 크기가 다른 행렬에도 적용 가능
- 컴퓨터 비전 영역에서 이미지 압축을 통한 패턴 인식과 신호 처리 분야에 사용됨
- LSA 기반 알고리즘

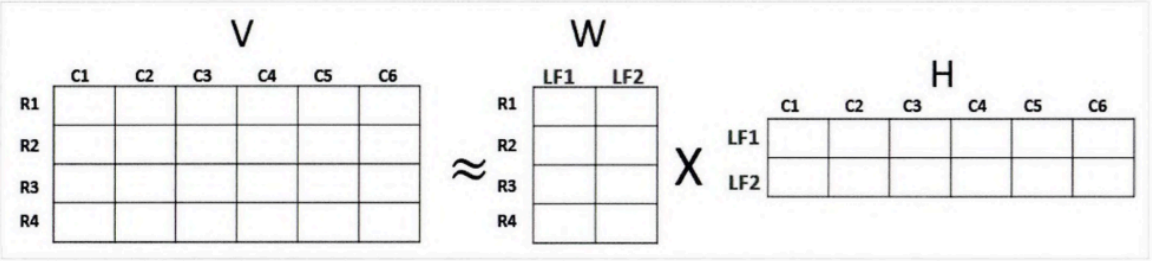
$$A = U \sum V^T$$



05. NMF (Non-Negative Matrix Factorization)

NMF 개요

- NMF는 Truncated SVD와 같이 낮은 랭크를 통한 행렬 근사 방식의 변형
- 추천 영역에 활발하게 적용됨
- 보통 길고 가는 행렬 W와 얕고 넓은 행렬 H로 분해
- W: 원본 행에 대해서 잠재요소의 값이 얼마나 되는지
- H: 잠재요소가 원본 열(속성)로 어떻게 구성됐는지


V
C1 C2 C3 C4 C5 C6
R1
R2
R3
R4
≈
W
LF1 LF2
R1
R2
R3
R4
X
H
C1 C2 C3 C4 C5 C6
LF1
LF2