

CHAPTER 4. 분류


01. 분류(Classification) 개요

앙상블(Ensemble)

- 여러 개의 학습기를 결합하여 예측 성능을 향상시키는 방법
- 정형 데이터의 예측 분석에서 높은 성능을 보임

앙상블 종류

앙상블



02. 결정 트리(Decision Tree)

결정 트리

- 데이터에 있는 규칙을 학습을 통해 자동으로 찾아내 트리(Tree) 기반의 분류 규칙을 만드는 것
- 루트 노드 **Root Node**: 트리의 시작점
- 규칙 노드 **Decision Node**: 새로운 규칙 조건마다 규칙 노드 기반의 서브 트리가 생성됨
- 리프 노드 **Leaf Node**: 결정된 클래스 값

결정 트리의 특징

장점

- 균일도를 기반으로 하여, 알고리즘이 단순하고 직관적으로 이해하기 쉬움
- 데이터가 어떻게 분류되는지 과정을 확인하기 쉽고, 시각화로 표현 가능
- 각 피처의 스케일링이나 정규화 같은 전처리 작업이 필요 없음

단점

- 과적합으로 정확도가 떨어짐

- 학습 데이터에 지나치게 최적화되면 새로운 데이터에서 성능이 떨어질 수 있음
-

결정 트리 파라미터

- 분류용으로 `DecisionTreeClassifier`를 사용
- 회귀용으로 `DecisionTreeRegressor`를 사용
- 결정 트리는 **CART** 알고리즘을 기반으로 구현됨.

주요 하이퍼파라미터

- `[min_samples_split]`: 노드를 분할하기 위한 최소한의 샘플 데이터 수로 과적합을 제어하는 데 사용
- `[min_samples_leaf]`: 분할될 경우 왼쪽과 오른쪽의 브랜치 노드에서 가져야 할 최소한의 샘플 데이터 수
- `[max_features]`: 최적의 분할을 위해 고려할 최대 피처 개수, 디폴트는 **None**
- `[max_depth]`: 트리의 최대 깊이를 규정, 디폴트는 **None**
- `[max_leaf_nodes]`: 말단 노드(Leaf)의 최대 개수

결정 트리 모델의 시각화

- `Graphviz`를 사용해 결정 트리 알고리즘이 어떤 규칙으로 트리를 생성하는지 시각적으로 볼 수 있음
 - `export_graphviz()` API
 - `Graphviz`가 읽어 들어서 그래프 형태로 시각화할 수 있는 출력 파일을 생성함
 - 생성된 출력 파일 `'tree.dot'`을 `Graphviz`의 파이썬 래퍼 모듈을 호출해 결정 트리의 규칙을 시각적으로 표현함

결정 트리 과적합(Overfitting)

- 복잡한 모델은 학습 데이터 세트의 특성과 약간 다른 형태의 데이터 세트를 예측하면 예측 정확도가 떨어지게 됨
 - 학습 데이터에만 지나치게 최적화된 분류 기준은 오히려 테스트 데이터 세트에서 정확도를 떨어뜨릴 수 있음
-

03. 앙상블 학습(Ensemble Learning)

앙상블 학습 개요

- 여러 개의 분류기를 생성하고, 결합하여 더 좋은 최종 예측을 도출하는 방법
- 대부분의 정형 데이터 분류 시에는 앙상블이 뛰어난 성능을 보임
- 편하면서도 강력한 성능을 보유하고 있음

앙상블의 대표적인 방식

- 보팅 Voting
 - 여러 개의 분류기가 투표를 통해 최종 예측 결과를 결정
 - 서로 다른 알고리즘을 가진 분류기를 결합
- 배깅 Bagging
 - 여러 개의 분류기가 투표를 통해 최종 예측 결과를 결정
 - 각각의 분류기가 모두 같은 유형의 알고리즘 기반
 - 데이터 샘플링을 서로 다르게 가져가면서 학습을 수행
 - 대표 알고리즘 → Random Forest
- 부스팅 Boosting
 - 이전 모델이 잘못 예측한 부분을 다음 모델이 보완할 수 있도록 가중치를 부여하며 진행
 - 예측 성능이 뛰어나 앙상블 학습을 주도함
 - 대표 알고리즘 → 그래디언트 부스트, XGBoost, LightGBM

보팅 유형

여러 개의 분류기가 예측한 결과를 투표하여 최종 클래스를 결정하는 방식.

Hard Voting

- 예측한 결과값들 중 다수의 분류기가 결정한 예측값을 최종 보팅 결과값으로 선정

Soft Voting

- 분류기들의 레이블 값 결정 확률을 모두 더하고 이를 평균해서 이들 중 확률이 가장 높은 레이블 값을 최종 보팅 결과값으로 선정
- 예측 성능이 더 좋아 일반적인 보팅 방법으로 적용됨

Voting Classifier

- 사이킷런은 보팅 방식의 앙상블을 구현한 **VotingClassifier** 클래스를 제공함
 - 보팅으로 여러 개의 기반 분류기를 결합한다고 해서 무조건 기반 분류기보다 예측 성능이 향상되지는 않음
-

04. 랜덤 포레스트(Random Forest)

랜덤 포레스트의 개요 및 실습

- 배깅의 대표적인 알고리즘
- 앙상블 알고리즘 중 비교적 빠른 수행 속도, 높은 예측 성능을 보임
- 결정 트리의 쉽고 직관적인 장점을 그대로 가지고 있음

부트스트래핑 분할 방식

- 여러 개의 데이터 세트를 중첩되게 분리하는 것
- 랜덤 포레스트의 서브셋 데이터를 임의로 만듦
- 데이터가 중첩된 개별 데이터 세트에 결정 트리 분류기를 각각 적용하는 것 = 랜덤 포레스트

랜덤 포레스트 하이퍼파라미터 및 튜닝

- 트리 기반 앙상블 알고리즘 단점: 이퍼 파라미터가 너무 많고, 그로 인해서 튜닝을 위한 시간이 많이 소모됨 -> 튜닝 후 예측 성능이 크게 향상되는 경우가 많지 않음