

Week3_예습과제

CH04 분류

1. 분류의 개요

분류 (Classification) : 기존 데이터가 어떤 레이블(명시적인 정답)에 속하는지에 대한 피쳐 (데이터의 특징)와 레이블 간의 패턴을 *알고리즘으로 인지한 뒤 새롭게 관측된 데이터에 대한 레이블을 판별하는 것. 지도학습의 대표적인 유형

*분류를 구현하는 다양한 알고리즘


- 나이브 베이즈(Naive Bayes) : 베이즈 통계와 생성 모델에 기반
- 로지스틱 회귀(Logistic Regression) : 독립변수-종속변수의 선형 관계성에 기반
- 결정 트리(Decision Tree) : 데이터 균일도에 따른 규칙 기반
- 서포트 벡터 머신(Support Vector Machine) : 개별 클래스 간의 최대 분류 마진을 효과적으로 찾아줌
- 최소 근접(Nearest Neighbor)알고리즘 : 근접 거리를 기준으로
- 신경망(Neural Network) : 심층 연결 기반
- **앙상블(Ensemble)** : 여러 머신러닝 알고리즘 결합, 정형 데이터의 예측 분석 영역에서 애용됨.
 - 배깅(Bagging) → 랜덤 포레스트,
 - 부스팅(Boosting) → 그래디언트(Gradient) 부스팅 → XGBoost, LightGBM

*스태킹 : 앙상블의 앙상블

*결정 트리 : 앙상블의 좋은 약한 학습기. 앙상블은 매우 여러 개의 약한 학습기(=예측 성능이 상대적으로 떨어지는 학습 알고리즘)을 결합해 확률적 보완과 오류 발생 부분에 대한 가중치 업데이트를 하면서 예측 성능을 향상시킴.

2. 결정 트리

결정 트리 : 데이터에 있는 규칙을 학습을 통해 자동으로 찾아내 트리 기반의 분류 규칙 만드는 알고리즘. if/else 기반으로 예측을 위한 규칙을 만듦.



데이터 세트의 피쳐(데이터에서 뽑아낸 특징)를 결합해 규칙을 만들 때마다 규칙 노드 생성.

결정 노드가 많다 = 규칙이 많다=분류결정방식이 복잡하다⇒과적합 위험

→ 가능한 적은 결정 노드로 높은 예측 정확도를 가지려면 최대한 많은 데이터 세트가 해당 분류에 속할 수 있어야

⇒ 최대한 균일한 데이터 세트를 구성할 수 있도록 분할(규칙노드로 나누기)하는 것이 필요

결정 노드 : 정보 균일도가 높은 데이터 세트를 먼저 선택할 수 있도록 규칙 조건 만들, 조건을 찾아 서브 데이터 세트 만들고 다시 이 서브 데이터 세트에서 균일도가 높은 자식 데이터 세트로 쪼개는 방식을 자식 트리 노드로 내려가면서 반복.

정보 균일도 측정 방식 : 이 지수들을 이용해 좋은 조건 찾음.


정보 이득 : $1 - \text{엔트로피지수} / \text{엔트로피지수}$ → 데이터 집합의 혼잡도

지니 계수 : 0에 가까울수록 평등, 1로 갈수록 불평등, DecisionTreeClassifier은 기본으로 지니계수 이용.

결정 트리 알고리즘 : 리프노드 // 데이터 분할해 Branch 노드 생성, 이 것을 자식 트리 노드에 걸쳐 반복적으로 분할한 뒤 데이터가 모두 특정 분류에 속하면 분할을 멈추고 분류를 결정.

결정 트리 장/단점 : 데이터 균일도만 고려 → 직관적, 사전 가공의 영향도 크지x but... 과적합 → 알고리즘 성능 떨어짐. ⇒ 이를 극복하기 위해 트리의 크기를 사전에 제한(튜닝)해야

결정 트리 파라미터 :



사이킷런이 제공하는 결정트리 알고리즘 클래스 : DecisionTreeClassifier(분류), DecisionTreeRegressor(회귀) 클래스

CART(Classification And Regression Tree) : 사이킷런의 결정 트리 구현에 사용되는 알고리즘

Graphviz 패키지 : 결정 트리 모델을 시각화할 수 있는 패키지

export graphviz(학습이 완료된 Estimator, 피처의 이름 리스트, 레이블 이름 리스트) : 학습된 결정 트리 규칙을 시각화

브랜치노드 : 자식 노드가 있는 노드. 자식 노드를 만들기 위한 분할 조건 있음.

리프노드 : 더 이상 자식 노드가 없는 노드. 최종 클래스(레이블) 값이 결정되는 노드. 리프 노드가 되려면 오직 하나의 클래스 값으로 최종 데이터가 구성되거나 리프 노드가 될 수 있는 하이퍼 파라미터 조건을 충족하면 됨.

*노드 속 value = [] 의 의미 : 클래스 값 기반의 데이터 건수, [0, 1, 2]라면 두번째, 세번째 클래스에 해당하는 데이터가 각각 한개, 두개 있다는 뜻. 완전하게 분류된 노드의 경우 하나의 클래스에만 데이터들이 속해있음(ex. [0, 0, 20])

*색깔이 짙어질수록 지니 계수가 낮고 해당 레이블에 속하는 샘플 데이터가 많다는 의미

*최종 리프 노드들의 색깔로 종류를 구별.

feature_importances_ 속성 : 사이킷런이 제공하는 DecisionTreeClassifier객체의 속성. ndarray 형태로 값 반환해 피쳐 순서대로 중요도에 해당하는 값이 할당, 피쳐가 트리 분할 시 정보 이득이나 지니 계수를 얼마나 효율적으로 잘 개선시켰는지를 정규화된 값으로 표현.

feature importance를 추출한 뒤, feature 별 importance 매핑하면 피쳐의 이름과 중요도 함께 나옴.

결정 트리 과적합(Overfitting) :

make_classification() : 분류를 위한 테스트용 데이터 세트 만드는 메소드

Ex. 2개의 피쳐, 3가지 유형의 클래스로 샘플 데이터 만들기

```
X_features, y_labels =  
make_classification(n_features=2, n_redundant=0, n_infor  
mative=2, n_classes=3, n_clusters_per_class=1, random_st  
ate=0)
```

결과 : 각 피쳐가 x,y축인 이차원 형태의 그래프 생성, 3개의 클래스 값은 색깔로 구분됨.

*visual_boundary(데이터세트명, 피쳐, 레이블) 정의해서 색상과 경계로 데이터 세트의 분류 결과를 시각화해주는 함수 만들기

```
def visualize_boundary(model, X, y):  
    plt.figure(figsize=(8, 6))  
  
    # 학습 데이터 산점도 그리기  
    plt.scatter(X[:, 0], X[:, 1], c=y, cmap=plt.cm.RdYlBu,  
                edgecolors='k', s=25)  
  
    # 결정 경계 시각화를 위한 그리드 생성  
    x_min, x_max = X[:, 0].min() - 1, X[:, 0].max() + 1  
    y_min, y_max = X[:, 1].min() - 1, X[:, 1].max() + 1  
    xx, yy = np.meshgrid(np.arange(x_min, x_max, 0.02),  
                          np.arange(y_min, y_max, 0.02))  
  
    Z = model.predict(np.c_[xx.ravel(), yy.ravel()])  
    Z = Z.reshape(xx.shape)
```

```
plt.contourf(xx, yy, Z, alpha=0.3, cmap=plt.cm.RdYlB
u)
plt.show()
```


3. 앙상블 학습

앙상블 학습을 통한 분류 : 여러 개의 분류기(Classifier)를 생성하고 그 예측을 결합함으로써 보다 정확한 최종 예측을 도출하는 기법, 정형 데이터 분류 시에 뛰어난 성능을 보임(이미지, 영상, 음성 등 비정형 데이터의 분류는 딥러닝이 뛰어난 성능을 보임)

대표적인 앙상블 알고리즘 : 랜덤 포레스트, 그래디언트 부스팅 알고리즘

앙상블 학습의 유형 :

보팅(Voting), 배깅(Bagging), 부스팅(Boosting), 이 외 스택킹 등이 있음.



보팅 : 여러 개의 서로 다른 알고리즘을 가진, 같은 데이터셋을 보는 분류기가 투표를 통해 최종 예측 결과 결정

배깅 : 여러 개의 같은 유형의 알고리즘을 가진, 서로 다른 데이터 샘플링을 가져간 분류기가 투표를 통해 최종 예측 결과 결정 ex. 랜덤 포레스트 알고리즘

*부트스트래핑 분할 방식 : 개별 분류기에 데이터를 샘플링해서 추출하는 방식

배깅 앙상블 : 개별 분류기가 부트 스트래핑 방식으로 샘플링 된 데이터 세트에 대해서 학습을 통해 개별적인 예측을 수행한 결과를 보팅을 통해 최종 예측 결과를 선정하는 방식. 데이터 세트 간 중첩 허용.

부스팅 : 여러 개의 분류기가 순차적으로 학습을 수행하되, 앞에서 학습한 분류기가 예측이 틀린 데이터에 대해서는 올바르게 예측할 수 있도록 다음 분류기에게는 가중치를 부여해서 학습, 예측을 진행하는 방식. 계속해서 분류기에게 가중치 부스팅함. 예측 성능이 뛰어나 앙상블 학습을 주도함.

보팅 유형 - 하드 보팅, 소프트 보팅

하드 보팅 : 예측한 결과값들 중 다수의 분류기가 결정한 예측값 = 최종 보팅 결과값

소프트 보팅 : 분류기들의 레이블 값 결정 확률을 모두 더하고 이를 평균해서 이들 중 확률이 가장 높은 레이블 값을 최종 보팅 결과값으로. 일반적인 보팅 방법

보팅 분류기(Voting Classifier)

사이킷런은 보팅 방식의 앙상블을 구현한 VotingClassifier 클래스를 제공

VotingClassifier의 주요 생성 인자 : estimators, voting 값

estimators : 리스트 값으로 보팅에 사용될 여러 개의 Classifier 객체들을 튜플 형식으로 입력 받음


voting : 'hard' → 하드보팅 // 'soft' → 소프트보팅

보팅 분류기 의의 : 현실 세계는 다양한 변수와 예측이 어려운 규칙으로 구성되기에 다양한 관점을 가진 알고리즘이 결합해 더 나은 성능을 실제 환경에서 끌어낼 수 있음.

앙상블 학습에서는 결정 트리 알고리즘의 단점을 매우 많은 분류기를 결합해 다양한 상황을 학습하게 함으로써 극복, 결정 트리 알고리즘의 장점을 그대로 취하며 *편향-분산 트레이드 오프의 효과 극대화 가능

4. 랜덤 포레스트 - 배깅의 대표적인 알고리즘

랜덤 포레스트의 기반 알고리즘 : 결정 트리



부트스트래핑 분할 방식 : 전체 데이터 중 일부가 중복되게 샘플링되는 데이터 세트로 분리
 서브세트(Subset) 데이터 : 부트스트래핑으로 데이터가 임의로 만들어짐.

⇒ 이렇게 중복된 서브세트 데이터에 결정 트리 분류기를 각각 적용하는 것이 랜덤 포레스트!

사이킷런은 RandomForestClassifier클래스 지원

랜덤 포레스트 하이퍼 파라미터 튜닝

n_estimators : 랜덤 포레스트 내 결정 트리 개수 지정

max_features : ~=결정 트리에서 사용되는 max_features 파라미터와 같음. 기본은 'auto'

이 외에도 max_depth과 같이 결정트리 과적합을 개선하기 위해 사용되는 파라미터도 랜덤 포레스트에도 똑같이 적용될 수 있음