

3주차 예습과제_김유진

3주차 예습과제

[4장] 분류

- 분류(Classification)의 개요
 - 결정 트리
 - 앙상블 학습
 - 랜덤 포레스트
-

01 분류의 개요

- **분류**는 지도학습(명시적인 정답이 있는 데이터가 주어진 상태에서 학습하는 머신러닝)의 대표적 유형
- 학습 데이터로 주어진 데이터의 피처와 레이블값(결정 값, 클래스 값)을 머신러닝 알고리즘으로 학습해 모델 생성 및 예측
- 분류는 다양한 머신러닝 알고리즘으로 구현 가능

앙상블


- 배깅 방식 (Bagging)과 부스팅(Boosting) 방식
- 배깅 방식의 대표인 랜덤 포레스트는 뛰어난 예측 성능, 빠른 수행 시간, 유연성
- 서로 다른/또는 같은 알고리즘을 결합

결정 트리

- 예측 성능을 향상시키기 위해 복잡한 규칙 구조를 가져야 하며, 과적합이 발생해 예측 성능 저하

02 결정 트리

- 데이터에 있는 규칙을 통해 자동으로 찾아내 트리 기반의 분류 규칙을 만드는 것
- 규칙 노드: 규칙 조건이 되는 것
- 리프 노드: 결정된 클래스
- 트리의 깊이가 깊어질수록 결정 트리의 예측 성능이 저하될 가능성이 높음



- 적은 결정 노드로 높은 예측 정확도를 가지려면 어떻게 트리를 분할할 것인가가 중요함
- 결정 노드는 정보 균일도가 높은 자식 데이터 세트를 먼저 선택할 수 있도록 규칙 조건을 만듦

→ 정보 균일도가 데이터 세트로 쪼개질 수 있도록 조건을 찾아 서브 데이터 세트를 만들고, 다시 이 서브 데이터 세트에서 균일도가 높은 자식 데이터 세트 쪼개는 방식을 자식 트리도 내려가면서 반복하는 방식으로 데이터 값을 예측

- 정보 균일도를 측정하는 대표적인 방법: 정보 이득 지수, 지니 계수

정보 이득 지수

정보 이득 지수는 1에서 엔트로피 지수를 뺀 값.

정보 이득 높은 속성을 기준으로 분할

지니 계수

0이 가장 평등하고 1로 갈수록 불평등

지니 계수가 낮을수록 데이터 균일도 ↑, 지니 계수 낮은 속성을 기준으로 분할

결정 트리 모델의 특징

- '균일도'를 기반으로 하고 있어서 알고리즘이 쉽고 직관적
- 피쳐 스케일링과 정규화 같은 전처리 과정 필요 X

결정 트리 장점	결정 트리 단점
쉽다. 직관적이다	과적합으로 알고리즘 성능 떨어짐
사전 가공 영향도 작다	트리의 크기를 사전에 제한할 튜닝 필요

결정 트리 파라미터

파라미터명	설명
max_depth	트리 최대 깊이 제한(깊으면 복잡도↑, 과적합↑)
min_samples_split	노드를 분기시키기 위한 최소 샘플 수
min_samples_leaf	리프(말단 노드)에 남겨야 하는 최소 샘플 수
max_features	분기 시 고려할 특성 수 제한(랜덤성 부여, 일반화 도움)
max_leaf_nodes	말단 노드의 최대 개수

결정 트리 모델의 시각화

- gini는 다음의 `valued`]로 주어진 데이터 분포에서의 지니 계수
- `samples`는 현 규칙에 해당하는 데이터 건수
- `value = [ ]`는 클래스 값 기반의 데이터 건수

결정 트리 과적합, 결정 트리 실습

- 리프를 계속 쪼개면 학습 데이터의 잡음까지 설명
- 결정 트리의 경우 분류를 위해 리프 노드가 될 수 있는 적합한 수준이 될 때까지 지속해서 트리의 분할을 수행하면서 깊이가 깊어짐


03 앙상블 학습

앙상블 학습 개요


앙상블 학습을 통한 분류: 여러 개의 분류기를 생성하고 그 예측을 결합함으로써 보다 정확한 최종 예측을 도출하는 기법

- 목표: 단일 분류기보다 신뢰성이 높은 예측값 얻는 것
- 학습 유형: 보팅(Voting), 배깅(Bagging), 부스팅(Boosting)

	배깅(Bagging)	보팅(Voting)
공통점	여러 개의 분류기가 투표를 통해 최종 결과 예측	
차이점	각각의 분류기가 모두 같은 유형의 알고리즘이지만, 데이터 샘플링 다름	서로 다른 알고리즘을 가진 분류기 결합



Voting 방식



Bagging 방식

보팅 유형 - 하드 보팅(Hard Voting)과 소프트 보팅(Soft Voting)

하드 보팅

- 각 모델의 **최종 클래스**를 다수결로 결정
- 장점: 단순, 확률 출력 없이도 가능

- 단점: 확률 정보를 버림

소프트 보팅

- 각 모델의 클래스 확률을 평균(또는 가중 평균)해 최종 결정
- 보통 하드 보팅보다 성능 잘 나옴
- 전제: 확률 출력 가능 or 확률 보정 잘 되어야함


보팅 분류기

- 서로 다른 성향의 모델을 섞을수록 이득 ↑
- 성능 좋은 모델에 더 큰 가중치

04 랜덤 포레스트

랜덤 포레스트의 개요 및 실습

- 앙상블 알고리즘 중 빠른 수행 속도
- 여러 개의 결정 트리 분류기가 전체 데이터에서 배깅 방식으로 각자의 데이터를 샘플링해 개별적으로 학습을 수행한 뒤 최종적으로 모든 분류기가 보팅을 통해 예측 결정
- **랜덤 포레스트**: 데이터가 중첩된 개별 데이터 세트에 결정 트리 분류기를 각각 적용하는 것



- 부트스트래핑(bootstrapping): 여러 개의 데이터 세트를 중첩되게 분리하는 것

랜덤 포레스트 하이퍼 파라미터 및 튜닝

- `n_estimators` : 랜덤 포레스트에서 결정 트리의 개수를 지정 (늘릴수록 학습 수행 시간 ↑)
- `class_weight`: 불균형 데이터에서 중요
- `max_features`는 결정 트리에 사용된 `maxfeatures` 파라미터와 같음.
`max_features`는 'None'이 아니라 `auto(sqrt)`와 같음
- `max_depth`: 트리 깊이(깊으면 과적합 경향)
- `max_features`: 분기마다 고려할 특성 수
- 랜덤 포레스트는 효과적으로 수행되어 빠른 학습 가능. BUT 예측 성능 약간 ↓