

3주차 예습과제 (pp.181-221)

☼ 상태	Done
👤 담당자	이서윤(인공지능대학 인공지능데이터사이언스학부)
📅 마감일	09/21/2026
📁 작업 유형	

4. 분류

분류(Classification)의 개요

지도학습의 대표적인 유형인 **분류(Classification)** - 학습 데이터로 주어진 데이터의 피처와 레이블값(결정 값, 클래스 값)을 머신러닝 알고리즘으로 학습해 모델을 생성하고, 이렇게 생성된 모델에 새로운 데이터 값이 주어졌을 때 미지의 레이블 값을 예측하는 것

머신러닝 알고리즘을 통한 분류 구현

- 나이브 베이즈(Naive Bayes)
- 로지스틱 회귀(Logistic Regression)
- 결정 트리(Decision Tree)
- 서포트 벡터 머신(Support Vector Machine)
- 최소 근접(Nearest Neighbor) 알고리즘
- 심층 연결 기반의 신경망(Neural Network)

앙상블 학습(Ensemble Learning)

- 여러 개의 학습 알고리즘을 결합하여 더 높은 예측 성능을 얻는 머신러닝 기법
- 서로 다른 알고리즘을 결합할 수도 있지만, 일반적으로 동일한 알고리즘을 여러 개 결합
- 이미지·영상·음성·NLP에서는 딥러닝이 주로 활용되지만, 정형 데이터의 예측·분류에서는 앙상블 기법이 높은 성능을 보임

앙상블 방식	특징	대표 알고리즘
배깅(Bagging)	여러 모델을 학습시킨 후 결과를 결합	Random Forest

앙상블 방식	특징	대표 알고리즘
부스팅(Boosting)	이전 모델의 오류를 다음 모델이 보완하며 순차적으로 학습	Gradient Boosting, XGBoost, LightGBM
스태킹(Stacking)	여러 모델의 예측 결과를 다시 다른 모델이 학습하여 최종 예측	Stacking

- **Random Forest:** 대표적인 배깅 방식. 높은 예측 성능, 빠른 수행 시간, 높은 유연성이 장점
- **Gradient Boosting:** 높은 예측 성능을 가지지만 수행 시간이 오래 걸려 모델 튜닝이 어려움
- **XGBoost / LightGBM:** Gradient Boosting의 예측 성능과 수행 속도를 개선한 부스팅 알고리즘으로, 정형 데이터 분석에서 많이 활용
- **Stacking:** 여러 모델을 결합하는 '앙상블의 앙상블' 방식


결정 트리(Decision Tree)와 앙상블

- 앙상블의 기본 학습 알고리즘으로 결정 트리가 주로 사용됨
- 장점: 적용이 쉽고 유연하며 데이터 스케일링·정규화 등 사전 가공의 영향을 적게 받음
- 단점: 복잡한 트리를 만들 경우 과적합(Overfitting)이 발생하여 예측 성능이 떨어질 수 있음
- 앙상블에서는 여러 결정 트리를 결합하여 개별 트리의 단점을 보완할 수 있으며, 결정 트리는 앙상블의 대표적인 약한 학습기로 활용됨

결정 트리

데이터에 있는 규칙을 학습을 통해 자동으로 찾아내 트리(Tree) 기반의 분류 규칙을 만드는 것

if/else 기반 - 데이터의 어떤 기준을 바탕으로 규칙을 만들어야 가장 효율적인 분류가 될 것인가가 알고리즘의 성능을 크게 좌우함



많은 규칙이 있음 → 분류를 결정하는 방식이 더욱 복잡해짐 → 과적합으로 이어지기 쉬움
가능한 한 적은 결정 노드로 높은 예측 정확도를 가지려면 데이터를 분류할 때 최대한 많은 데이터 세트가 해당 분류에 속할 수 있도록 결정 노드의 규칙이 정해져야 한다

결정 트리의 분할 기준

- 결정 트리는 데이터를 **최대한 균일하게 분할할 수 있는 속성**을 기준으로 노드를 나눔.
- 데이터 균일도를 측정하는 대표적인 방법은 **정보 이득(Information Gain)**과 **지니 계수(Gini Index)**가 있음.

1. 정보 이득(Information Gain)


- 엔트로피(Entropy): 데이터의 혼잡도를 나타내는 지표
 - 서로 다른 값이 많이 섞임 → 엔트로피 ↑
 - 같은 값으로 구성됨 → 엔트로피 ↓
- 정보 이득 = 1 - 엔트로피 지수
- 결정 트리는 정보 이득이 높은 속성을 기준으로 분할

2. 지니 계수(Gini Index)

- 데이터의 불균일 정도를 나타내는 지표
- 지니 계수가 낮을수록 데이터 균일도가 높음
- 따라서 지니 계수가 낮은 속성을 기준으로 분할
- `DecisionTreeClassifier` 는 기본적으로 지니 계수를 사용

결정 트리 분할 과정

정보 이득이 높거나 지니 계수가 낮은 조건 선택 → 데이터 분할 → 자식 노드에서 반복 → 데이터가 특정 분류에 속하면 분할 종료



결정 트리 모델의 특징

정보의 '균일도'라는 룰을 기반으로 하고 있어서 알고리즘이 쉽고 직관이다

결정 트리 장점	결정 트리 단점
• 쉽다. 직관적이다 • 피처의 스케일링이나 정규화 등의 사전 가공 영향도가 크지 않음.	• 과적합으로 알고리즘 성능이 떨어진다. 이를 극복하기 위해 트리의 크기를 사전에 제한하는 튜닝 필요.

결정 트리 파라미터

`DecisionTreeClassifier` - 분류를 위한 클래스, `DecisionTreeRegressor` - 회귀를 위한 클래스
 사이킷런의 결정 트리 구현은 **CART(Classification And Regression Trees)** 알고리즘 기반이다

파라미터 명	설명
<code>min_samples_split</code>	노드를 분할하기 위한 최소한의 샘플 데이터 수로 과적합을 제어하는 데 사용됨
<code>min_samples_leaf</code>	분할이 될 경우 왼쪽과 오른쪽의 브랜치 노드에서 가져야 할 최소한의 샘플 데이터 수
<code>max_features</code>	최적의 분할을 위해 고려할 최대 피처 개수

파라미터 명	설명
max_depth	트리의 최대 깊이를 규정
max_leaf_nodes	말단 노드(Leaf)의 최대 개수

결정 트리 모델의 시각화

Graphviz 패키지 사용

[ipynb 코드 실습](#)

결정 트리 과적합(Overfitting)

[ipynb 코드 실습](#)

결정 트리 실습 - 사용자 행동 인식 데이터 세트


[ipynb 코드 실습](#)

앙상블 학습

앙상블 학습 개요

앙상블 학습(Ensemble Learning)을 통한 분류 - 여러 개의 분류기(Classifier)를 생성하고 그 예측을 결합함으로써 보다 정확한 최종 예측을 도출하는 기법

앙상블 학습의 목표 - 다양한 분류기의 예측 결과를 결합함으로써 단일 분류기보다 신뢰성이 높은 예측값을 얻는 것



앙상블 학습의 유형

앙상블 학습의 대표적인 유형은 **보팅(Voting)**, **배깅(Bagging)**, **부스팅(Boosting)**이며, 이외에 **스태킹(Stacking)** 등이 있음

1. 보팅(Voting)

- 서로 다른 알고리즘의 여러 분류기를 동일한 데이터로 학습
- 각 분류기의 예측 결과를 **투표(Voting)**하여 최종 결과 결정
- 예: 선형 모델 + KNN + SVM → 투표 → 최종 예측

2. 배깅(Bagging)

- 같은 알고리즘을 사용하는 여러 분류기를 활용
- 각 분류기는 원본 데이터에서 **서로 다르게 샘플링된 데이터**로 학습
- 각 분류기의 예측 결과를 **투표하여 최종 결과 결정**
- 대표 알고리즘: **Random Forest**

→ 부트스트래핑(Bootstrapping)

- 원본 데이터에서 각 분류기의 학습 데이터를 **복원 추출**하는 방식
- 동일한 데이터가 여러 번 선택되는 **중복을 허용**
- 교차 검증은 데이터 세트 간 중복을 허용하지 않는 반면, 배깅의 부트스트래핑은 **중복을 허용**

3. 부스팅(Boosting)


- 여러 분류기를 **순차적으로 학습**
- 앞의 분류기가 **잘못 예측한 데이터에 가중치(Weight)**를 부여하여 다음 분류기가 더 잘 학습하도록 함
- 이전 모델의 오류를 계속 보완하면서 **예측 성능을 향상**
- 대표 알고리즘: **Gradient Boosting, XGBoost, LightGBM**

4. 스태킹(Stacking)


- 여러 모델이 만든 **예측 결과를 새로운 학습 데이터로 사용**
- 이 데이터를 다시 **메타 모델(Meta Model)**이 학습하여 최종 예측

보팅 유형 - 하드 보팅(Hard Voting)과 소프트 보팅(Soft Voting)

Hard Voting은 다수의 classifier 간 다수결로 최종 class 결정



Soft Voting은 다수의 classifier들의 class 확률을 평균하여 결정



하드 보팅 - 다수결 원칙과 비슷하며 예측한 결과값들 중 다수의 분류기가 결정한 예측값을 최종 보팅 결과값으로 선정하는 것

소프트 보팅 - 분류기들의 레이블 값 결정 확률을 모두 더하고 이를 평균해서 이들 중 확률이 가장 높은 레이블 값을 최종 보팅 결과값으로 선정함

일반적으로 하드 보팅보다는 소프트 보팅이 예측 성능이 좋아서 더 많이 사용된다

보팅 분류기(Voting Classifier)

사이킷런은 보팅 방식의 앙상블을 구현한 `VotingClassifier` 클래스를 제공함

[ipynb 코드 실습](#)

- 여러 분류기를 결합한다고 해서 항상 단일 모델보다 성능이 좋은 것은 아님
 - 데이터의 특성·분포에 따라 가장 성능이 좋은 단일 모델이 더 우수할 수도 있음
- 하지만 일반적으로 보팅·배깅·부스팅 등의 앙상블은 단일 모델보다 높은 예측 성능을 보이는 경우가 많음
- 여러 모델을 결합하여 다양한 상황을 학습하고 서로의 약점을 보완할 수 있기 때문

랜덤 포레스트

랜덤 포레스트의 개요 및 실습

- 배깅(Bagging)의 대표적인 알고리즘
- 같은 알고리즘인 여러 개의 결정 트리(Decision Tree)를 결합하여 최종 예측
- 비교적 수행 속도가 빠르고 다양한 영역에서 높은 예측 성능을 보임
- 결정 트리를 기반으로 하므로 쉽고 직관적이라는 장점을 가짐

랜덤 포레스트의 학습 과정

- ① 원본 데이터 → 부트스트래핑으로 여러 데이터 세트 생성
- ② 각 데이터 세트 → 각각의 결정 트리가 학습
- ③ 여러 결정 트리가 각각 예측
- ④ 예측 결과를 보팅(Voting) → 최종 예측

부트스트래핑(Bootstrapping)

- 원본 데이터에서 복원 추출하여 여러 학습 데이터 세트를 만드는 방법
- 데이터의 중복을 허용하여 샘플링
- 각 서브 데이터 세트의 데이터 개수는 원본 데이터와 동일하지만, 같은 데이터가 여러 번 포함될 수 있음
- **Bagging = Bootstrap + Aggregating**
 - Bootstrap: 여러 학습 데이터 생성
 - Aggregating: 여러 모델의 결과를 결합

사이킷런

- 분류용 랜덤 포레스트는 `RandomForestClassifier` 클래스로 구현

랜덤 포레스트 하이퍼 파라미터 및 튜닝

주요 하이퍼파라미터

- `n_estimators`
 - 생성할 결정 트리의 개수
 - 증가시키면 성능이 좋아질 수 있지만 무조건 향상되는 것은 아님
 - 트리가 많아질수록 학습 시간 증가
- `max_features`
 - 각 트리의 노드를 분할할 때 참조할 피처의 개수
 - 일반적으로 전체 피처 중 일부만 무작위로 선택하여 사용
- `max_depth`, `min_samples_split`, `min_samples_leaf` 등은 결정 트리와 마찬가지로 과적합 방지에 활용됨

ipynb 코드 실습