

04. 분류 - Part3 & 캐글 노트북 1,2

09. 분류 실습 - 캐글 산탄데르 고객 만족

| 데이터 전처리

XGBoost는 사이킷런 래퍼 이용, 필요한 모듈을 로딩하고 학습 데이터를 DataFrame으로 로딩

해당 데이터에는 클래스 값 칼럼을 포함한 피처가 371개 존재

↳ 111개의 피처가 float, 260개의 피처가 int, NULL 값은 없음

학습과 성능 평가를 위해 원본 데이터 세트에서 학습 데이터 세트와 테스트 데이터 세트를 분리 → 비대칭한 데이터 세트이므로 클래스인 Target 값 분포도가 학습 데이터와 테스트 데이터 세트에 모두 비슷하게 추출됐는지 확인

| XGBoost 모델 학습과 하이퍼 파라미터 튜닝

XGBoost의 학습 모델 생성, 예측 결과를 ROC AUC로 평가

↳ 테스트 데이터 세트로 예측 시 ROC AUC는 약 0.8429

HyperOpt를 이용해 베이지안 최적화 기반으로 XGBoost의 하이퍼 파라미터 튜닝 수행 → 목적 함수 만들기 → fmin() 함수를 호출해 max_eval=50회를만큼 반복하면서 최적의 하이퍼 파라미터를 도출

이렇게 도출된 최적 하이퍼 파라미터를 기반으로 XGBClassifier를 재학습시키고 테스트 데이터 세트에서 ROC AUC를 측정

↳ 0.8429에서 하이퍼 파라미터 튜닝 이후 0.8457로 개선됨

XGBoost가 GBM보다는 빠르지만 GBM을 기반으로 하고 있기 때문에 수행 시간이 상당히 더 많이 요구됨.

| LightGBM 모델 학습과 하이퍼 파라미터 튜닝

앞의 XGBoost 예제 코드에서 만들어진 데이터 세트를 기반으로 LightGBM으로 학습을 수행하고, ROC-AUC를 측정

↳ ROC AUC는 약 0.8384

HyperOpt를 이용하여 다양한 하이퍼 파라미터에 대한 튜닝을 수행 → 목적 함수 생성 → `fmin()`을 호출하여 최적 하이퍼 파라미터 도출

이들 하이퍼 파라미터를 이용하여 LightGBM을 학습 후에 테스트 데이터 세트에서 ROC-AUC를 평가

↳ ROC AUC가 약 0.8446

캐글 노트북 1 - Decision Tree And Random Forest Classifier Models

| Data Review

데이터셋에 문자열 타입의 데이터가 포함 → 모델을 학습시킬 때는 문자열 타입의 데이터를 그대로 사용할 수 없기 때문에, 데이터셋을 학습에 사용할 수 있도록 전처리하는 과정에서 각 컬럼에 어떤 데이터가 있는지 확인할 필요가 있음

| Data Visualization

데이터셋에 Plotly 라이브러리를 적용해서 시각화

| Classifications Models

학습을 위한 데이터셋을 준비하고, 여러 모델을 사용하여 학습을 진행

Data Preparing

문자열 데이터를 정수형으로 변환 이후 학습 데이터와 테스트 데이터로 분할

Decision Tree Classifier

Decision Tree Classifier는 지도학습 기법 중 하나로, 분류와 회귀 문제 모두에 사용할 수 있지만, 주로 분류 문제를 해결하는데에 사용됨.

- Internal nodes: 데이터셋의 특성을 나타냄
- Branches: 각 특성에 대한 의사결정 규칙을 나타냄
- Leaf nodes: 최종적인 예측 결과를 나타냄

Random Forest Classifier

Random Forest는 지도학습에 속하는 대표적인 머신러닝 알고리즘. 머신러닝에서 분류와 회귀 문제 모두에 사용가능

랜덤 포레스트는 앙상블 학습을 기반으로 함. 앙상블 학습은 여러 개의 분류 모델을 결합하여 하나의 복잡한 문제를 해결하고, 모델의 성능을 향상시키는 방법임.

Evaluation Classification Models

머신러닝 모델의 성능을 평가하는 것은 효과적인 머신러닝 모델을 구축하는 데 있어 중요한 과정 중 하나임. 모델의 성능이나 품질을 평가하기 위해 다양한 평가 지표가 사용됨



Confusion Matrix

Confusion Matrix는 이진 분류 모델의 예측 결과를 표 형태로 나타낸 것. 실제 값을 알고 있는 테스트 데이터를 사용하여 분류 모델이 얼마나 정확하게 예측했는지 평가하는 데 사용됨.

캐글 노트북2 - Beginner Friendly CATBOOST with OPTUNA

| Data

▼ 심부전 예측 데이터셋

Age: 환자의 나이

Sex: 환자의 성별

ChestPainType: 흉통 유형

RestingBP: 안정 시 혈압

Cholesterol: 공복 혈당

RestingECG: 안정 시 심전도 결과

MaxHR: 최대 심박수

ExerciseAngina: 운동 유발 협심증 여부

Oldpeak: 운동 시 ST 분절의 하강 정도를 나타내는 수치

ST_Slope: 운동 시 최대 ST 분절의 기울기

HeartDisease: 출력 클래스

What Problem We Have and Which Metric to Use?

- 주어진 데이터와 데이터 사전을 바탕으로 분류 문제임을 알 수 있음
- 목표 변수인 HeartDisease를 기준으로 환자의 심장 질환 여부를 분류
- 목표 변수에 대한 분류 성능이 가장 좋은 모델을 구축하는 것이 목적
- 목표 변수의 데이터 분포가 균형적인지 확인
- 목표 변수는 비교적 균형 잡힌 데이터를 가지고 있음
- 모델의 성능을 평가하기 위한 지표로 정확도를 사용

Model Selection

- Dummy Classifier 모델을 기준 모델로 사용
- 이후 Logistic Regression, Linear Discriminant Analysis, K-Nearest Neighbors, Support Vector Machine 모델을 스케일링 적용 전후로 비교
- 다음으로 앙상블 모델인 AdaBoost, Random Forest, Gradient Boosting, Extra Trees를 사용
- 머신러닝에서 유명한 XGBoost, LightGBM, CatBoost 세 가지 모델을 살펴봄
- 마지막으로 CatBoost의 하이퍼 파라미터 튜닝

Conclusion

심장 질환 여부를 분류하기 위한 모델을 구축 → EDA를 수행 → 모델의 성능을 평가하기 위해 사용할 평가 지표를 결정 → 목표 변수와 특성 분석 → 범주형 변수를 모델에서 사용할 수 있도록 수치형 변수로 변환 → Data Leakage를 방지하기 위해 Pipeline을 사용 → 각 모델의 결과를 비교, 해당 문제에 가장 적합한 최적의 모델을 선정 → CatBoost 모델을 자세히 살펴봄 → Optuna를 이용해 CatBoost의 하이퍼파라미터 튜닝을 수행, 성능 향상 변화 확인 → Feature Importance를 확인