

5주차 과제

(파머완 4장 4.9장 & 캐글 notebook 1, 2 개념 정리 & 필사)


4장 분류

4.9 분류 실습 - 캐글 신용카드 사기 검출

언더 샘플링과 오버 샘플링의 이해

레이블이 불균형한 분포를 가진 데이터 세트를 학습시킬 때 예측 성능의 문제가 발생할 수 있음 → 이는 이상 레이블을 가지는 데이터 건수가 정상 레이블을 가진 데이터 건수에 비해 너무 적기 때문에 발생.

⇒ 이상 레이블을 가지는 데이터 건수는 매우 적기 때문에 제대로 다양한 유형을 학습 x , 반면에 정상 레이블을 가지는 데이터 건수는 매우 많기 때문에 일방적으로 정상 레이블로 치우친 학습을 수행해 제대로 된 이상 데이터 검출 어려워짐



언더 샘플링


많은 데이터 세트를 적은 데이터 세트 수준으로 감소시키는 방식
ex. 정상 레이블을 가진 데이터: 10,000건, 이상 레이블 가진 데이터: 100건 → 정상 레이블 데이터를 100건으로 줄이는 방식

오버 샘플링

이상 데이터와 같이 적은 데이터 세트를 증식하여 학습을 위한 충분한 데이터를 확보하는 방법
과적합 위험 존재
→ 원본 데이터의 피쳐 값들을 아주 약간만 변경하여 증식

▼ ex. SMOTE

적은 데이터 세트에 있는 개별 데이터들의 K 최근접 이웃을 찾아서 이 데이터와 K개 이웃들의 차이를 일정 값으로 만들어서 기존 데이터와 약간 차이가 나는 새로운 데이터들을 생성하는 방식




코드 필사에서 이어서~


이상치 데이터 제거 후 모델 학습/예측/평가

이상치 데이터(Outlier): 전체 데이터의 패턴에서 벗어난 이상 값을 가진 데이터

- IQR(Inter Quantile Range) 방식: 사분위 값의 편차를 이용하는 기법



▼ 박스 플롯



캐글 notebook1

(코드 필사에서~)

캐글 notebook2

<DATA DICTIONARY>

1. **Age:** Age of the patient [years]
2. **Sex:** Sex of the patient [M: Male, F: Female]
3. **ChestPainType:** [TA: Typical Angina, ATA: Atypical Angina, NAP: Non-Anginal Pain, ASY: Asymptomatic]
4. **RestingBP:** Resting blood pressure [mm Hg]
5. **Cholesterol:** Serum cholesterol [mm/dl]
6. **FastingBS:** Fasting blood sugar [1: if FastingBS > 120 mg/dl, 0: otherwise]
7. **RestingECG:** Resting electrocardiogram results [Normal: Normal, ST: having ST-T wave abnormality (T wave inversions and/or ST elevation or depression of > 0.05 mV), LVH: showing probable or definite left ventricular hypertrophy by Estes' criteria]
8. **MaxHR:** Maximum heart rate achieved [Numeric value between 60 and 202]

9. **ExerciseAngina**: Exercise-induced angina [Y: Yes, N: No]
10. **Oldpeak**: ST [Numeric value measured in depression] (
11. **ST_Slope**: The slope of the peak exercise ST segment [Up: upsloping, Flat: flat, Down: downsloping]
12. **HeartDisease**: Output class [1: heart disease, 0: Normal]

<What Problem We Have and Which Metric to Use?>

- Based on the data and data dictionary, We have a classification problem.
- We will make classification on the target variable **Heart Disease**
- And we will build a model to get best classification possible on the target variable.
- For that we will look at the balance of the target variable.
- As we will see later, our target variable has balanced or balanced like data
- For that reason we will use **Accuracy score**.

(코드 필사에서~)