

CHAPTER 5

5.1 회귀 소개

회귀란?

- 데이터 값이 평균과 같은 일정한 값으로 돌아가려는 경향을 이용한 통계학 기법

회귀의 종류

* 독립변수의 개수

- 단일 회귀: 독립변수 1개
- 다중 회귀: 독립변수 여러 개

* 회귀 계수의 결합

- 선형 회귀: 회귀 계수가 선형으로 결합
- 비선형 회귀: 회귀 계수가 비선형으로 결합

지도학습의 종류

- 분류: 예측값이 카테고리나 같은 이산적인 값
- 회귀: 예측값이 연속적인 숫자값

선형 회귀

- 실제값과 예측값의 차이를 최소화하는 직선형 회귀선을 최적화하는 방식
 - 규제 방법에 따라 별도의 유형으로 나뉨
 - 일반적인 선형 회귀의 과적합 문제를 해결하기 위해서 회귀 계수에 페널티 값을 적용하는 것
 - 대표 모델
 - 일반 선형 회귀 / 릿지 / 라쏘 / 엘라스틱넷 / 로지스틱 회귀
-

5.2 단순 선형 회귀를 통한 회귀 이해

단순 선형 회귀

- 독립변수 1개 + 종속변수 1개로 이루어진 선형 회귀
- 예측값 = $w_0 + w_1 * X$
 - 기울기 w_1 과 절편 w_0 을 회귀 계수로 지칭
- 실제값 = 1차 함수 값에서 실제 값만큼의 오류 값을 뺀(또는 더한)값이 됨
 - $w_0 + w_1 * X + \text{오류 값}$

잔차

- 실제값과 회귀 모델의 예측값 사이의 차이 = 오류값
- 최적의 회귀 모델 = 전체 데이터의 잔차(오류 값) 합이 최소가 되는 모델

RSS(비용함수)

$$RSS = \sum(\text{실제값} - \text{예측값})^2$$

- 회귀 모델 구축 = **RSS**를 최소화하는 최적의 회귀 계수 찾기
 - 비용함수 = 손실함수
-

5.3 비용 최소화하기 - 경사 하강법 소개

경사 하강법(Gradient Descent)

- '점진적으로' 반복적인 계산을 통해 **w** 파라미터 값을 업데이트하면서 오류 값이 최소가 되는 **W** 파라미터를 구하는 방식
- 반복적으로 예측값과 실제 값의 차이가 작아지는 방향성을 가지고 **W** 파라미터를 지속해서 보정함
- 수행 시간이 오래 걸림

확률적 경사 하강법

- 일반적인 경사 하강법은 전체 데이터를 이용해 반복적으로 비용을 계산하기 때문에 데이터가 많으면 시간이 오래 걸림 -> 확률적 경사 하강법 사용
 - 일부 데이터만 이용해 **w**가 업데이트되는 값을 계산
 - 대용량 데이터에서는 확률적 경사 하강법 또는 미니 배치 확률적 경사 하강법을 사용
-

5.4 사이킷런 **LinearRegression** 이용한 보스턴 주택가격 예측

LinearRegression 클래스

- 실제값과 예측값의 **RSS**를 최소화해 OLS(Ordinary Least Squares) 추정 방식으로 구현한 클래스
- **fit()** 메서드로 **X, y** 배열을 입력받으면 회귀 계수인 **W**를 **coef_** 속성에 저장

회귀 평가 지표

- 실제 값과 회귀 예측값의 차이 값을 기반으로 한 지표가 중심
- 오류의 절댓값 평균이나 제곱, 또는 제곱한 뒤 다시 루트를 씌운 평균값을 구해서 적용

*MAE (Mean Absolute Error)

- 실제 값과 예측값의 차이를 절댓값으로 변환해 평균한 것

*MSE (Mean Squared Error)

- 실제 값과 예측값의 차이를 제곱해 평균한 것

*RMSE (Root Mean Squared Error)

- MSE에 루트를 씌운 것

*R² (R-Squared)

- 실제 값의 분산 대비 예측값의 분산 비율을 지표로 하며, 1에 가까울수록 예측 정확도가 높음

5.5 다항 회귀와 과소적합/과적합 이해

다항 회귀(Polynomial Regression)

- 회귀가 독립변수의 단항식이 아닌 2,3차 방정식과 같은 다항식으로 표현되는 것
- $y = w_0 + w_1X + w_2X^2 + w_3X^3 \rightarrow$ 여전히 선형 회귀임

다항 회귀를 이용한 과소적합 및 과적합 이해

- 다항식의 차수가 높아질수록 더 복잡한 관계를 표현할 수 있음
- but 차수가 지나치게 높아지면 학습 데이터에만 지나치게 맞는 과적합이 발생
- 단순히 차수를 높이는 것이 좋은 것이 아니라 적절한 차수 선택이 중요

편향-분산 트레이드오프(Bias-Variance Trade-off)

- 고편향: 매우 단순화된 모델, 지나치게 한 방향으로 치우친 경향
- 고분산: 학습데이터들의 특성을 반영하며 매우 복잡한 모델, 지나치게 높은 변동성을 지닌 것

- 편향과 분산은 한쪽이 높으면 한쪽이 낮아지는 경향이 있음
 - 편향과 분산이 서로 트레이드오프를 이루면서 오류 **Cost** 값이 최대로 낮아지는 모델을 구축하는 것이 가장 효율적인 머신러닝 예측 모델을 만드는 방법임

5.6 규제 선형 모델 - Ridge, Lasso, Elastic Net

규제 선형 모델의 개요

- 회귀 모델 = 데이터에 적합하면서도 회귀 계수가 기하급수적으로 커지는 것을 제어해야 함
- 비용 함수는 학습 데이터의 잔차 오류 값을 최소로 하는 **RSS** 최소화 방법과 과적합을 방지하기 위해 회귀 계수 값이 커지지 않도록 하는 방법이 서로 균형을 이뤄야 함

$$\text{Cost} = \text{RSS} + \alpha \times \text{규제항}$$

- α (alpha) → 규제의 강도를 조절하는 하이퍼파라미터
- α 가 커질수록 회귀 계수에 대한 규제가 강해진다.
- 너무 작은 α → 규제 효과 부족
- 너무 큰 α → 모델이 지나치게 단순해질 수 있음

릿지 회귀

- 주요 생성 파라미터 = **alpha** = 릿지 회귀의 **alpha L2** 규제 계수
- **alpha** 값이 커질수록 회귀 계수 값이 작아짐
- 릿지 회귀는 회귀 계수를 0으로 만들지는 않음

라쏘 회귀

- W의 절댓값에 페널티를 부여하는 **L1** 규제를 선형 회귀에 적용한 것
 - **L2** 규제 = 회귀 계수의 크기를 감소시킴
 - **L1** 규제 = 불필요한 회귀 계수를 급격하게 감소시켜 0으로 만들고 제거함
- 적절한 피처만 회귀에 포함시키는 피처 선택의 특성을 지님
- 주요 생성 파라미터 = **alpha** = 라쏘 회귀의 **alpha L1** 규제 계수
- **alpha**의 크기가 증가함에 따라 일부 피처의 회귀 계수는 0으로 바뀜
 - 회귀 계수가 0인 피처는 회귀 식에서 제외되면서 피처 선택의 효과를 얻을 수 있음

엘라스틱넷 회귀

- **L1 + L2** 규제를 결합한 회귀
- ElasticNet 클래스를 통해 회귀를 구현, 주요 생성 파라미터는 **alpha**와 **l1_ratio**
 - ElasticNet 클래스의 **alpha** 파라미터 값은 $a + b$
 - ElasticNet 클래스의 **l1_ratio** 파라미터 값은 $a / (a + b)$
- 엘라스틱넷의 규제는 $a * L1 + b * L2$
 - a 는 L1 규제의 **alpha**값, b 는 L2 규제의 **alpha** 값
 - **l1_ratio**가 0이면 a 가 0이므로 L2 규제와 동일
 - **l1_ratio**가 1이면 b 가 0이므로 L1 규제와 동일

선형 회귀를 위한 데이터 변환

- 선형 모델은 일반적으로 피처와 타깃값 간에 선형의 관계가 있다고 가정하고, 이러한 최적의 선형함수를 찾아내 결괏값을 예측함
- 피처값과 타깃값의 분포가 정규 분포 (즉 평균을 중심으로 종 모양으로 데이터 값이 분포된 형태) 형태를 매우 선호

로그 변환

- 데이터 분포가 심하게 왜곡되어 있을 경우 사용
- 큰 값을 상대적으로 작게 만들어 분포의 왜곡을 완화
- 특히 타깃값의 분포가 심하게 치우쳐 있을 때 유용함

5.7 로지스틱 회귀

로지스틱 회귀 개요

- 선형 회귀 방식을 분류에 적용한 알고리즘 -> 분류에 사용됨
- 시그모이드 함수 최적선을 찾고, 해당 시그모이드 함수의 반환 값을 확률로 간주해 확률에 따라 분류를 결정함
- 데이터의 정규 분포도에 따라 예측 성능 영향을 받을 수 있음
- 가볍고 빠르지만, 이진 분류 예측 성능도 뛰어나
- 희소한 데이터 세트 분류에도 뛰어난 성능을 보여서 텍스트 분류에서도 자주 사용됨

5.8 회귀 트리

회귀 트리 개요

- 회귀를 위한 트리를 생성하고 이를 기반으로 회귀 예측을 하는 것
- 회귀 계수를 기반으로 하는 최적 회귀 함수를 도출하는 것이 주요 목표
- 리프 노드에 속한 데이터 값의 평균값을 구해 회귀 예측값을 계산함
- 분할되는 데이터 지점에 따라 브랜치를 만들면서 계단 형태로 회귀선을 만듦