6주차

날짜	2026년 10월 13일
다중 선택	
텍스트	파머완 5장(5.9, 5.10 제외)

5장. 회귀

01. 회귀 소개

- 회귀: 여러 개의 독립변수(피처)와 한 개의 종속변수(결정값) 간의 상관관계를 모델링하는 기법
  - 유래: 갈톤의 키 연구, 사람의 키는 평균으로 회귀하려는 경향이 있음
  - 예시: 방 개수, 방 크기, 주변 학군(독립변수) → 아파트 가격(종속변수)
- 회귀식: Y = W1·X1 + W2·X2 + … + Wn·Xn
  - Y: 종속변수, X: 독립변수, W: 회귀 계수
- 머신러닝 관점
  - 독립변수 = 피처, 종속변수 = 결정값
  - 핵심: 주어진 피처와 결정값 데이터로 학습해 최적의 회귀 계수를 찾는 것
- 회귀 유형 구분
  - 독립변수 개수: 1개 → 단일 회귀 / 여러 개 → 다중 회귀
  - 회귀 계수의 결합: 선형 → 선형 회귀 / 비선형 → 비선형 회귀
- 분류 vs 회귀: 분류는 예측값이 이산값(카테고리), 회귀는 연속값(숫자)
- 대표적인 선형 회귀 모델
  - 일반 선형 회귀: RSS를 최소화하도록 계수 최적화, 규제 없음
  - 릿지(Ridge): 선형 회귀 + L2 규제
  - 라쏘(Lasso): 선형 회귀 + L1 규제
  - 엘라스틱넷(ElasticNet): L1 + L2 규제 결합
  - 로지스틱 회귀: 이름은 회귀지만 분류에 사용되는 선형 모델

- 규제(Regularization): 과적합 해결을 위해 회귀 계수에 페널티 값을 적용하는 것

---

02. 단순 선형 회귀를 통한 회귀 이해

- 단순 선형 회귀: 독립변수 1개, 종속변수 1개인 선형 회귀
  - 예측값 $\hat{Y} = w0 + w1 \cdot X$ (w1: 기울기, w0: 절편, 둘 다 회귀 계수)
- 잔차: 실제 값 - 회귀 모델 예측값 (남은 오류)
- 오류 합 계산 방식
  - 그냥 더하면 +, -가 상쇄되므로 절댓값 평균(MAE) 또는 제곱합(RSS) 사용
  - 미분 등 계산이 편리해 보통 RSS 사용
- $RSS(w0, w1) = (1/N) \Sigma (yi - (w0 + w1 \cdot xi))^2$
  - w(회귀 계수)가 변수이고 X, y는 모두 상수로 간주
  - RSS = 비용(Cost), 비용 함수 = 손실 함수(loss function)
- 최적의 회귀 모델 = 잔차 합(RSS)이 최소가 되는 회귀 계수를 찾는 것

---

03. 비용 최소화하기 - 경사 하강법

- 필요성: w 파라미터가 많아지면 고차원 방정식으로 푸는 것이 어려움
- 핵심 질문: "어떻게 하면 오류가 작아지는 방향으로 W 값을 보정할 수 있을까?"
- 원리
  - 비용 함수를 미분한 값(기울기)이 감소하는 방향으로 W를 반복 업데이트
  - 기울기가 더 이상 감소하지 않는 지점 = 비용 함수 최소 지점 → 그때의 W 반환
- 업데이트 식: 새로운 w = 이전 w - $\eta \times$ (편미분 값), η = 학습률(보정 계수)
- 일반적인 프로세스
  - Step 1. w1, w0를 임의 값으로 설정 후 비용 함수 값 계산
  - Step 2. w1, w0 업데이트 후 비용 함수 값 다시 계산
  - Step 3. 비용 함수가 감소하는 방향으로 Step 2를 주어진 횟수만큼 반복
- 확률적 경사 하강법(SGD)
  - 전체 데이터가 아닌 일부 데이터(batch_size)만 사용해 업데이트 값 계산
  - 일반 경사 하강법보다 빠름 → 대용량 데이터에서는 SGD, 미니 배치 SGD 사용

    - 결과(w1, w0, 비용)는 일반 경사 하강법과 거의 차이 없음
- 피처가 여러 개인 경우
    - 예측 행렬 $\hat{Y} = X_mat \cdot W^T$ (선형대수로 간단히 계산)
    - w0를 W 배열에 포함시키기 위해 값이 모두 1인 피처(Feat 0)를 추가

---

04. 사이킷런 LinearRegression을 이용한 보스턴 주택 가격 예측

LinearRegression 클래스 - OLS(Ordinary Least Squares)

- 예측값과 실제 값의 RSS를 최소화하는 OLS 추정 방식으로 구현한 클래스
- fit()으로 X, y를 입력받으면 회귀 계수는 coef_, 절편은 intercept_ 속성에 저장
- 주요 파라미터: fit_intercept(절편 계산 여부, 기본 True), normalize
- 다중 공선성(multi-collinearity) 문제
    - 피처 간 상관관계가 매우 높으면 분산이 커져 오류에 민감해짐
    - 해결: 독립적인 중요 피처만 남기고 제거 / 규제 적용 / PCA로 차원 축소

회귀 평가 지표

지표	설명	Scoring 값
MAE	실제 값과 예측값 차이의 절댓값 평균	neg_mean_absolute_error
MSE	실제 값과 예측값 차이의 제곱 평균	neg_mean_squared_error
RMSE	MSE에 루트를 씌운 값	neg_root_mean_squared_error
R^2	분산 기반 예측 성능, 1에 가까울수록 정확	r2
MSLE, RMSLE	MSE, RMSE에 로그를 적용한 지표	-

- scoring 파라미터 주의점
    - 사이킷런은 값이 클수록 좋은 모델로 판단 → 오류 지표에 -1을 곱해 'neg_'를 붙임
    - cross_val_score 결과는 음수 → -1을 다시 곱해야 원래 MSE
    - RMSE는 0.22 버전부터 mean_squared_error(squared=False)로 구할 수 있음

보스턴 주택 가격 회귀

- 피처 중 RM(방 개수)은 양의 선형성, LSTAT(하위 계층 비율)는 음의 선형성이 가장 큼

- 결과: MSE 17.297, RMSE 4.159, R^2 0.757
- 5폴드 교차 검증 평균 RMSE: 5.829
- 회귀 계수: RM이 양의 값으로 가장 크고, NOX가 -19.8로 값이 매우 큼

---

05. 다항 회귀와 과(대)적합 / 과소적합 이해

다항 회귀 이해

- 다항 회귀: 독립변수의 2차, 3차 등 다항식으로 표현되는 회귀
- 다항 회귀도 선형 회귀
  - 선형/비선형 구분 기준은 독립변수가 아니라 회귀 계수가 선형인지 여부
  - 새로운 변수 Z로 치환하면 선형식으로 표현 가능
- 사이킷런 구현
  - 다항 회귀 전용 클래스는 없음 → PolynomialFeatures로 피처 변환 후 LinearRegression 적용
  - degree 파라미터: 단항식 피처를 degree에 해당하는 다항식 피처로 변환
  - fit(), transform()으로 변환, Pipeline으로 변환과 회귀를 한 번에 연결 가능

다항 회귀를 이용한 과소적합 및 과적합 이해

- 코사인 곡선 데이터에 degree를 1, 4, 15로 변경하며 비교

degree	상태	MSE
1	과소적합 (단순 직선, 패턴 반영 못함)	약 0.41
4	적정 (실제 곡선과 유사)	약 0.04
15	과적합 (노이즈까지 학습, 회귀 계수 폭증)	약 1.8억

- 좋은 모델 = 학습 데이터의 패턴을 반영하면서도 복잡하지 않은 균형 잡힌 모델

편향-분산 트레이드오프(Bias-Variance Trade off)

- 고편향(High Bias): 지나치게 단순한 모델, 과소적합되기 쉬움
- 고분산(High Variance): 지나치게 복잡한 모델, 과적합되기 쉬움
- 한쪽이 높으면 다른 쪽이 낮아지는 관계 → 전체 오류(Cost)가 최소가 되는 지점이 목표

---

06. 규제 선형 모델 - 릿지, 라쏘, 엘라스틱넷

규제 선형 모델의 개요

- 비용 함수 목표 = Min(RSS(W) + alpha × ||W||)
  - RSS 최소화(학습 데이터 적합) + 회귀 계수 크기 제어의 균형
- alpha: 학습 데이터 적합 정도와 회귀 계수 크기 제어를 조절하는 튜닝 파라미터
  - alpha 크게 → 회귀 계수 작아짐 → 과적합 개선
  - alpha 작게 → 회귀 계수가 커져도 상쇄 가능 → 학습 데이터 적합 개선
- L2 규제: W의 제곱에 페널티 (릿지)
- L1 규제: W의 절댓값에 페널티 (라쏘)

릿지 회귀

- 선형 회귀 + L2 규제, Ridge 클래스(주요 파라미터 alpha)
- 상대적으로 큰 회귀 계수 값의 영향도를 줄이기 위해 계수를 더 작게 만듦
- alpha가 커질수록 계수가 작아지지만 0으로 만들지는 않음
- 결과: alpha=10에서 평균 RMSE 5.518 (규제 없는 LinearRegression 5.829보다 개선)

라쏘 회귀

- 선형 회귀 + L1 규제, Lasso 클래스
- 예측 영향력이 작은 피처의 회귀 계수를 0으로 만들어 제거 → 피처 선택 기능
- 결과: alpha=0.07에서 평균 RMSE 5.612
- alpha 증가 시 NOX, INDUS, CHAS 등의 계수가 0으로 변함

엘라스틱넷 회귀

- L2 + L1 규제 결합, ElasticNet 클래스
- 주로 피처가 많은 데이터 세트에 적용
  - L1로 피처 개수를 줄이고 L2로 계수 크기를 조정
  - 라쏘가 상관관계 높은 피처 중 하나만 선택하는 성향이 강해 alpha에 따라 계수가 급변하는 것을 완화
- 단점: 규제가 결합되어 수행 시간이 상대적으로 오래 걸림

- 주요 파라미터
  - alpha = a + b (a: L1 규제 alpha, b: L2 규제 alpha)
  - l1_ratio = a / (a + b), 0이면 L2 규제와 동일, 1이면 L1 규제와 동일
- 결과: alpha=0.5에서 평균 RMSE 5.467 (3가지 중 가장 좋음)

선형 회귀 모델을 위한 데이터 변환

- 선형 회귀는 피처값과 타깃값이 정규 분포 형태일 때 성능이 좋고, 왜곡된 분포는 성능에 부정적
- 피처 데이터 변환 방법
  1. 스케일링/정규화: StandardScaler(평균 0, 분산 1) 또는 MinMaxScaler(0~1)
  2. 스케일링/정규화 후 다항 특성 적용 (피처가 많으면 피처 수가 기하급수적으로 늘어 과적합 위험)
  3. 로그 변환(Log Transformation): 정규 분포에 가까운 형태로 변환, 실무에서 가장 많이 사용
- 타깃값은 일반적으로 로그 변환 적용
- 로그 변환은 np.log() 대신 np.log1p() 사용 (언더플로우 방지를 위해 값에 1을 더함)
- 결과: 보스턴 데이터에서 로그 변환 시 RMSE 4.7대로 가장 안정적으로 개선

---

07. 로지스틱 회귀

- 선형 회귀 방식을 분류에 적용한 알고리즘, 선형 회귀 계열
- 선형 함수의 회귀선이 아니라 시그모이드(Sigmoid) 함수 최적선을 찾고, 반환 값을 확률로 간주해 분류 결정
  - 시그모이드: y = 1 / (1 + e^(-x)), 출력은 항상 0~1 사이 (x=0일 때 0.5)
- 선형 회귀 직선보다 S자 커브가 0과 1 분류에 더 정확
- 사이킷런 LogisticRegression 주요 파라미터
  - solver: 최적화 방식 선택
    - lbfgs: 0.22부터 기본값, 메모리 절약, CPU 병렬 가능
    - liblinear: 0.21까지 기본값, 작은 데이터에 효과적, 병렬 불가
    - newton-cg: 정교하지만 대용량에서 느림

        - sag: 경사 하강법 기반, 대용량에서 빠름
        - saga: sag와 유사, L1 규제 가능
    - penalty: 규제 유형 (l2 기본, l1)
    - C: alpha의 역수(C = 1/alpha), 값이 작을수록 규제 강도가 큼
    - 규제 제약: liblinear, saga는 L1, L2 모두 가능 / lbfgs, newton-cg, sag는 L2만 가능
- 위스콘신 유방암 데이터: 정확도 약 0.98, ROC-AUC 0.995 (solver 간 차이는 미미)
- 특징: 가볍고 빠르며 이진 분류 성능이 뛰어나 기본 모델로 많이 사용, 희소한 데이터 세트(텍스트 분류)에서도 강력

---

08. 회귀 트리

- 회귀 함수 대신 결정 트리처럼 트리 기반으로 회귀 수행
- 예측 방식
    - 분류 트리: 리프 노드에서 특정 클래스 레이블 결정
    - 회귀 트리: 리프 노드에 속한 데이터 값의 평균값을 예측값으로 사용
- CART(Classification And Regression Trees) 알고리즘 기반이라 분류와 회귀 모두 가능
- 사이킷런 Estimator 클래스

알고리즘	회귀	분류
Decision Tree	DecisionTreeRegressor	DecisionTreeClassifier
Random Forest	RandomForestRegressor	RandomForestClassifier
Gradient Boosting	GradientBoostingRegressor	GradientBoostingClassifier
XGBoost	XGBRegressor	XGBClassifier
LightGBM	LGBMRegressor	LGBMClassifier

- 선형 회귀와 달리 회귀 계수(coef_)가 없음 → feature_importances_로 피처별 중요도 확인
- 보스턴 주택 가격 5폴드 평균 RMSE

모델	RMSE
DecisionTree	5.978

모델	RMSE
RandomForest	4.423
GradientBoosting	4.269
XGBoost	4.251
LightGBM	4.646

- 선형 회귀 vs 회귀 트리
  - 선형 회귀: 직선 형태의 예측선
  - 회귀 트리: 분할 지점마다 브랜치를 만들어 계단 형태의 예측선
  - max_depth가 클수록 이상치까지 학습해 과적합되기 쉬움 (max_depth=7)
