

Week6 예습과제

CHAPTER 05 | 회귀

▼ 5.1 회귀 소개

회귀의 목적

- 회귀(Regression)는 독립변수(피처)와 종속변수(타겟) 사이의 관계를 학습해 연속적인 수치 값을 예측하는 지도학습 방법이다. 주택 가격이나 매출액 예측이 대표적이다.
- 분류는 범주를, 회귀는 수치를 예측한다.

선형 회귀의 기본 형태

- 선형 회귀는 입력 피처들의 선형 결합으로 예측값을 나타낸다. 단일 피처는 $y = w_0 + w_1x$, 여러 피처는 $y = w_0 + w_1x_1 + \dots + w_nx_n$ 이다.
- w_0 는 절편, $w_1 \sim w_n$ 은 회귀 계수이며 학습은 이 계수를 정하는 과정이다.

주요 회귀 모델

- 일반 선형 회귀는 예측 오차를 줄이는 계수를 찾는다. 릿지는 L2 규제를, 라쏘는 L1 규제를, 엘라스틱넷은 L1과 L2 규제를 함께 적용한다.
- 로지스틱 회귀는 이름에 회귀가 들어가지만 분류에 사용한다.

▼ 5.2 단순 선형 회귀를 통한 회귀 이해

오차와 비용 함수

- 실제값 y 와 예측값 $\hat{y}$ 의 차이가 잔차(residual)이다. RSS(잔차 제곱합)는 $\sum (y - \hat{y})^2$ 이고, 이를 데이터 수 N 으로 나누면 MSE(평균 제곱 오차)가 된다. 제곱하기 때문에 큰 오차에 더 민감하다.

최적 회귀 계수

- 단순 선형 회귀에서는 직선의 기울기 w_1 과 절편 w_0 을 조정하여 RSS 또는 MSE를 최소화한다.
- 모든 점을 정확히 통과하는 직선을 찾는 것이 아니라, 전체 오차가 작아지는 직선을 찾는 것이다.

평가 지표

- MAE는 $|y - \hat{y}|$ 의 평균, MSE는 $(y - \hat{y})^2$ 의 평균, RMSE는 MSE의 제곱근이다. 세 지표는 작을수록 좋다.
- R^2 는 모델이 타겟 변동을 얼마나 설명하는지 나타내며 일반적으로 1에 가까울수록 좋지만 음수도 가능하다.

▼ 5.3 경사 하강법

핵심 원리

- 경사 하강법(Gradient Descent)은 비용 함수의 기울기(편미분)를 계산하고, 비용이 감소하는 방향으로 계수를 조금씩 업데이트하는 최적화 방법이다.
- 업데이트의 기본 형태는 $w \leftarrow w - \eta [\partial J(w)/\partial w]$ 이다.

학습률과 반복

- 학습률(learning rate)이 너무 크면 최솟값을 지나쳐 발산할 수 있고, 너무 작으면 수렴이 느리다.
- 반복 횟수(iterations)는 계수 갱신 횟수이며, 적절한 학습률과 반복 횟수가 중요하다.

실습 흐름

- 노이즈가 포함된 $y = 6 + 4X$ 형태의 데이터를 만들고, 비용 계산 함수와 가중치 갱신 함수를 정의한다.
- w_0 와 w_1 을 0에서 시작해 반복 갱신하고, 추정한 계수와 MSE를 확인한 뒤 산점도 위에 회귀선을 그린다.

확률적 경사 하강법

- 전체 데이터를 매번 사용하는 배치 경사 하강법과 달리, 확률적/미니배치 방식은 일부 데이터를 무작위로 추출해 갱신한다.
- 한 번의 업데이트 계산 부담이 줄지만 추정 기울기의 변동이 생길 수 있다. 교재 실습은 batch_size만큼 샘플을 뽑는다.

▼ 5.4 LinearRegression과 보스턴 주택 가격 예측

LinearRegression

- scikit-learn의 LinearRegression은 선형 회귀 모델을 학습하는 클래스이다. fit()으로 계수를 학습하고 predict()로 예측한다.
- intercept_는 절편, coef_는 각 피처의 회귀 계수다.

보스턴 데이터와 시각화

- 보스턴 주택 데이터의 여러 특성을 이용해 PRICE를 예측한다.
- RM(주택당 평균 방 수), LSTAT(하위 계층 비율) 등 피처와 가격의 관계를 regplot으로 살펴본다.
- 회귀 계수의 부호는 다른 피처가 일정할 때 예측 가격의 증가·감소 방향을 나타내지만, 곧바로 인과관계를 뜻하지 않는다.

학습·평가 및 교차 검증

- train_test_split으로 학습용과 평가용 데이터를 나눈 후 MSE, RMSE, R^2 를 확인한다.
- cross_val_score에서 scoring="neg_mean_squared_error"는 점수가 클수록 좋다는 규칙에 맞춰 MSE에 음수를 붙여 반환하므로, RMSE 계산 시 다시 부호를 바꾼다.
- 5-Fold는 데이터를 다섯 부분으로 나눠 평가한다.

버전 관련 참고

- 교재의 load_boston()은 최신 scikit-learn에서 제거되어 필사 실습에서는 동일한 보스턴 데이터의 대체 로딩이 필요하다. 이 변경은 모델 원리 자체의 변경은 아니다.

▼ 5.5 다항 회귀와 과적합·과소적합

다항 회귀

- 다항 회귀는 x^2 , x^3 , x_1x_2 같은 다항식 피처를 추가해 비선형 곡선 형태의 관계를 표현한다.
- 원래 입력값에 대해서는 곡선이어도 생성된 피처의 회귀 계수에 대해서는 선형 모델로 학습할 수 있다.

PolynomialFeatures와 Pipeline

- PolynomialFeatures(degree=n)는 지정한 차수까지 다항식 피처를 생성한다.
- Pipeline은 피처 변환과 LinearRegression 학습을 하나의 과정으로 연결해 실행과 교차 검증을 편리하게 한다.

과소적합·과적합

- 차수가 너무 낮으면 데이터의 실제 패턴을 충분히 표현하지 못해 과소적합(높은 편향)이 발생한다.
- 차수가 너무 높으면 노이즈까지 따라가 과적합(높은 분산)이 생길 수 있다.

- 실습은 degree 1, 4, 15를 비교하여 모델 복잡도와 검증 MSE의 관계를 살펴본다.

편향-분산 트레이드오프

- 단순한 모델은 편향이 높아 복잡한 패턴을 놓치기 쉽고, 복잡한 모델은 분산이 높아 데이터 변화에 민감할 수 있다.
- 중요한 것은 학습 오차만 낮추는 것이 아니라 새로운 데이터에서의 예측 성능을 높이는 것이다.

▼ 5.6 규제 선형 모델

규제의 필요성

- 규제(Regularization)는 오차를 줄이는 동시에 회귀 계수가 지나치게 커지는 것을 억제한다.
- 복잡한 모델의 과적합을 줄이고 일반화 성능을 개선하는 데 활용한다.
- alpha는 규제 강도를 조절한다.

릿지(Ridge) 회귀

- 릿지는 비용 함수에 L2 규제항(계수 제곱합)을 더한다.
- alpha가 커질수록 계수의 절댓값이 대체로 작아지며, 일반적으로 계수를 정확히 0으로 만들기보다는 축소한다.
- 실습에서는 여러 alpha에서 5-Fold RMSE와 피처별 계수를 비교한다.

라쏘(Lasso) 회귀

- 라쏘는 L1 규제항(계수 절댓값의 합)을 더한다.
- 일부 계수를 정확히 0으로 만들어 피처 선택과 비슷한 효과를 낼 수 있다.
- alpha를 지나치게 크게 하면 유용한 피처까지 제거되어 과소적합될 수 있다.

엘라스틱넷(ElasticNet)

- 엘라스틱넷은 L1과 L2 규제를 결합한다.
- alpha는 전체 규제 강도, l1_ratio는 두 규제의 혼합 비율을 정한다. 상관관계가 높은 피처가 많을 때 라쏘의 한계를 보완하려는 목적이 있다.

데이터 변환 실습

- StandardScaler는 평균 0·표준편차 1로 표준화하고, MinMaxScaler는 값의 범위를 조정한다.

- $\log_{1p}$ 는 로그 변환, PolynomialFeatures는 다항 피처를 추가한다. 교재는 이 변환 방법을 달리하여 릿지 회귀의 RMSE 변화를 비교한다.
- 로그 변환은 입력값의 정의역에 주의해야 한다.

▼ 5.7 로지스틱 회귀

분류 모델인 이유

- 로지스틱 회귀(Logistic Regression)는 선형 결합 결과에 시그모이드 함수를 적용해 0~1 사이의 확률을 계산한다.
- 확률을 기준으로 클래스를 구분하므로 연속값 예측이 아니라 분류에 사용한다.

실습과 평가

- 위스콘신 유방암 데이터를 StandardScaler로 표준화한 뒤 학습/테스트 데이터를 나눈다.
- LogisticRegression을 학습하고 accuracy(정확도)와 ROC-AUC를 평가한다.
- predict()는 클래스, predict_proba()는 클래스별 확률을 반환한다.

주요 파라미터

- solver는 최적화 알고리즘, C는 규제 강도의 역수이다.
- 따라서 C가 작을수록 규제가 강하다. penalty는 L1/L2 등의 규제 종류다.
- 모든 solver가 모든 penalty를 지원하는 것은 아니므로 GridSearchCV 조합에 주의한다.

▼ 5.8 회귀 트리

회귀 트리의 원리

- 회귀 트리는 분할 조건으로 데이터를 여러 영역으로 나누고, 각 말단 노드에 도달한 데이터의 대표값(보통 평균)으로 수치를 예측한다.
- 선형 회귀처럼 하나의 직선을 맞추는 대신 구간별 예측을 만든다.

대표 모델

- DecisionTreeRegressor는 단일 트리, RandomForestRegressor는 여러 트리의 예측을 평균하는 배깅 기반 앙상블이다.
- GradientBoostingRegressor, XGBRegressor, LGBMRegressor는 앞선 모델의 오차를 순차적으로 개선하는 부스팅 계열이다.

교재 실습

- 보스턴 주택 데이터에서 랜덤 포레스트의 5-Fold RMSE를 계산하고 여러 회귀 트리 모델의 성능을 비교한다.
- `feature_importances_`로 피쳐 중요도를 확인한다.
- 이어 RM 한 개 피쳐만 사용하여 선형 회귀와 `max_depth=2, 7`인 결정 트리의 예측선을 비교한다.

모델 복잡도

- 결정 트리의 `max_depth`가 커질수록 더 세밀하게 분할할 수 있지만, 노이즈나 이상치까지 따라가 과적합될 수 있다.
- 시각화에서 회귀 트리는 계단형 예측선을 보이며 선형 회귀와 형태가 다르다.