아보카도 가격 회귀

01. 노트북 개요

아보카도 평균 가격을 예측하는 회귀 문제를 EDA → 전처리 → PyCaret(AutoML) 순서로 해결하는 것

02. 데이터셋

변수	설명
AveragePrice	아보카도 1개의 평균 가격 (**타겟**)
Total Volume	총 판매 개수
4046 / 4225 / 4770	PLU 코드별 판매 개수
Total Bags, Small / Large / XLarge Bags	백 전체 및 사이즈별 판매 개수
type	conventional 또는 organic
year, region	연도, 지역

03. 초기 데이터 탐색

- type과 region은 고르게 분포함
- AveragePrice는 변동이 작고 약하게 오른쪽으로 치우침
- 나머지 수치형 변수는 심하게 오른쪽으로 치우쳐 있고 이상치가 많음

04. EDA 핵심 결과

- **종류**: conventional이 판매량은 훨씬 많고(최대 약 600만 vs 약 20만), organic이 가격은 더 높음
- **지역**: West와 California가 판매량 1, 2위이며, Hartford Springfield, New York, San Francisco가 가격 상위 지역임
- **PLU / 백**: PLU 4046과 4225가 대부분이고 4770은 적음. 백은 Small > Large > XLarge 순임
- **연도별 가격**: 2016년에 하락하고 2017년에 정점을 찍은 뒤 2018년에 다시 하락함

- **계절성**: organic 가격은 매년 8~9월에 정점을 찍고, conventional 판매량은 연말~2월에 증가함
- **상관관계**: 판매량, PLU, 백 변수끼리는 상관이 높고(0.6 이상), AveragePrice와 year는 상관이 낮음(0.1 미만)
- **이분산성**: Total Volume과 Total Bags 산점도가 원뿔 모양으로 퍼짐

05. 전처리와 PyCaret 설정

- Data를 datetime으로 변환해 month 칼럼을 추가

설정	값
타겟	AveragePrice
train / test	80% / 20%
범주형 변수	type, year, region, month
정규화	robust (이상치가 많기 때문)
저분산 피처	제거

06. 모델링 결과

- compare_models() (R^2 기준) 상위 3개는 Extra Trees(0.9284), Random Forest(0.9073), LightGBM(0.8904)임

모델	튜닝 여부	Train R^2	Test R^2
Extra Trees	튜닝 전	1.000	**0.925**
Extra Trees	튜닝 후	0.539	0.534
Random Forest	튜닝 전	0.988	0.903
Random Forest	튜닝 후	0.647	0.629
LightGBM	튜닝 전	0.913	0.879
LightGBM	튜닝 후	0.870	0.823

- 세 모델 모두 튜닝 후 오히려 성능이 떨어졌으며, 작성자는 PyCaret이 튜닝에 실패한 것으로 봄
- 중요 피처 1위는 Extra Trees와 Random Forest에서 type_organic, LightGBM에서 Total Volume임

- 튜닝하지 않은 **Extra Trees**를 최종 모델로 선택했고, finalize_model()로 재학습한 뒤 pickle 파일로 저장함