10주차 예습과제

[6장]

- 차원 축소 개요
- PCA(Principal Component Analysis)
- LDA(Liner Discriminant Analysis)
- SVD(Singular Value Decomposition)
- NMF(Non-Negative Martix Factorization)

---

1) 차원 축소 개요

차원이 많을 시의 문제점

- 데이터 포인트 간 거리가 기하급수적으로 멀어져 sparse한 구조
- 많은 피처 개수→ 신뢰도 저하
- 다중 공산성 문제 발생 가능성 증가

차원 축소 방식

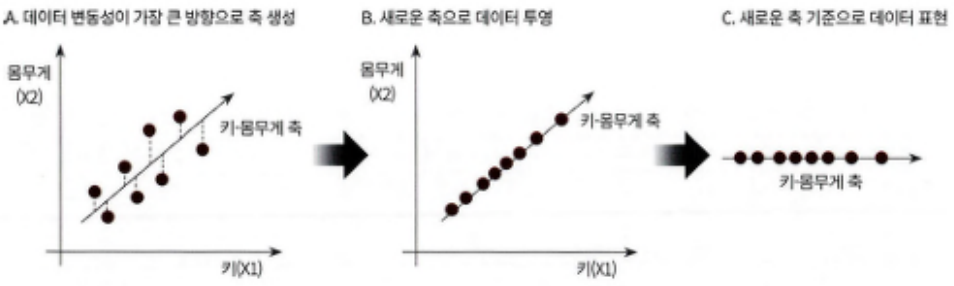
- 피처 선택(feature selection): 불필요한 피처 제거, 주요 피처만 선택
- 피처 추출(feature extraction): 기존 피처를 저차원의 중요 피처로 압축(기존 피처가 인지하기 어려웠던 잠재적 요소(Latent Factor를 추출)

활용분야

- 이미지-잠재 특성을 추출하여 과적합 영향력 감
- 텍스트 -문서 내 단어에서 숨겨진 시맨틱(Semantic)의미/토픽(Topic) 발견, SVD/NMF가 시맨틱 토픽 모델링 기반 알고리즘

2) PCA(Principal Component Analysis)

- 가장 대표적인 차원 축소 기법
- 여러 변수 간 상관관계를 이용해 이를 대표하는 주성분(Principal Component)을 추출해 차원 축소
- 기존 데이터의 정보 유실을 최소화하기 위해 가장 높은 분산(=데이터의 변동성)을 가지는 데이터의 축(=PCA의 주성분)을 기준으로 데이터를 투영해 차원 축소



PCA 주성분 구하기

- 첫 번째 주성분(PC1): 데이터가 가장 많이 퍼진 방향(최대 분산)
- 두 번째 주성분(PC2): PC1과 직교하면서 그 다음으로 분산이 큰 방향
- n+1 번째 주성분(PCn+1): PCn과 직교하면서 그 다음으로 분산이 큰 방향

→ 생성된 벡터 축 개수만큼의 차원으로 축소

선형대수 관점

: 공분산 행렬을 고유값 분해해서 고유벡터를 새로운 축으로 사용/공분산 행렬을 고유값 분해하면 고유값은 특정방향(고유 벡터)을 기준으로 공분산 행렬을 재해석했을 때의 분산의 크기

- 분산-한개 변수의 데이터 변동
- 공분산-두 변수 간의 변동
- 공분산 행렬: 모든 피처 간의 관계(분산+공분산)를 담은 전체 정보
    - 정방 행렬이자 대칭 행렬(→항상 고유벡터를 직교 행렬로, 고유값을 정방 행렬로 대각화 가능)
    - 분해 식: C = P Σ P^T
    - +) P: n x n 직교 행렬/Σ: n x n 정방 행렬/P^T: P의 전치 행

PCA 과정

1. 입력 데이터 세트의 공분산 행렬을 생성
2. 공분산 행렬의 고유벡터와 고유값을 계산
3. 고유값이 가장 큰 순으로 K개(PCA 변환 차수)만큼 고유벡터를 추출
4. 고유값이 가장 큰 순으로 추출된 고유벡터를 이용해 새롭게 입력 데이터를 변환

3) LDA(Linear Discriminant Analysis)

선형 판별 분석법

PCA와 유사하게 저차원 공간에 투영해 차원 축소

- 차이점: LDA는 지도학습의 분류에서 사용하기 쉽도록 개별 클래스를 분별할 수 있는 기준을 최대한 유지하면서 차원 축소→결정 값 클래스를 최대한으로 분리할 수 있는 축 찾음
- 클래스 결정 값 필요-지도학습(PCA는 비지도)

클래스 간 분산(between-class scatter) 최대화 + 클래스 내부 분산(within-class scatter) 최소→ **두 분산의 비율을 최대화**하는 방식으로 차원 축소

LCA 과정

1. 클래스 내부(S_W)와 클래스 간(S_B) 분산 행렬 구하기(피처의 평균 벡터 기반)
2. (S_W)^T x S_B 행렬을 고유벡터로 분해
3. 고유값이 큰 순으로 K개(LDA 변환 차수) 추출
4. 추출된 고유벡터로 새롭게 입력 데이터 변환

$$S_W^T S_B = \begin{bmatrix} e_1 & \cdots & e_n \end{bmatrix} \begin{bmatrix} \lambda_1 & \cdots & 0 \\ \cdots & \cdots & \cdots \\ 0 & \cdots & \lambda_n \end{bmatrix} \begin{bmatrix} e_1^T \\ \cdots \\ e_n^T \end{bmatrix}$$

4) SVD(Singular Value Decomposition)

특이값 분해

PCA와 유사

- 차이점: PCA는 정방행렬만 분해 가능, SVD는 행과 열 크기가 다른 행렬에도 적용 가능

분해 식: A = U Σ V^T

- A(m x n): 원본 행렬
- U(m x m): 좌측 특이벡터(직교 벡터)
- Σ(m x n): 대각행렬, 대각 원소 = 특이값(singular value)
- V^T(n x n): 우측 특이벡터의 전치(직교 벡터)

Compact SVD vs Truncated SVD

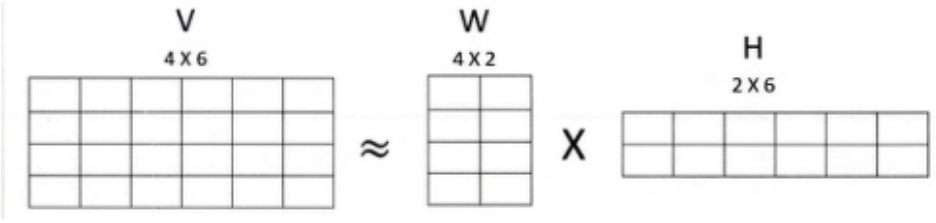
- Compact: Σ에서 특이값이 0인 부분 제거→U-m x p, Σ는 p x p, V^T는 p x n
- Truncated: Σ의 대각원소 중 상위 일부만 추출→더 작은 차원으로 분해, 근사적 복

5) NMF(Non-Negative Martix Factorization)

Truncated SVD와 같이 낮은 랭크를 통한 행렬 근사(Low-Rank Approximation)방식의 변형

원본 행렬 내 모든 원소가 양수일 때 두개의 양수 행렬로 분해 가능

분해 식:



- W: 길고 가는 행렬(행 크기 = 원본의 행 크기)→잠재 요소의 값이 얼마나 되는지 대응
- H: 작고 넓은 행렬(열 크기 = 원본의 열 크기)→잠재 요소가 원본 열로 어떻게 구성되었는지 표현

→ 분해된 행렬은 잠재 요소(Latent Factor)를 특성으로 가