06. 차원 축소

01. 차원 축소(Dimension Reduction) 개요

> **차원 축소**

매우 많은 피처로 구성된 다차원 데이터 세트의 차원을 축소에 새로운 차원의 데이터 세트를 생성하는 것

- 일반적으로 차원이 증가할수록 데이터 포인트 간의 거리가 기하급수적으로 멀어지게 되고, 희소한 구조를 가지게 됨
- 피처가 많을 경우 예측 신뢰도가 떨어지고, 개별 피처 간의 상관관계가 높을 가능성이 큼
- 매우 많은 다차원의 피처를 차원 축소해 피처 수를 줄이면 더 직관적으로 데이터를 해석할 수 있음
- 일반적으로 차원 축소는 피처 선택(feature selection)과 피처 추출(feature extraction)로 나눌 수 있음

❓ 피처 선택

- 특정 피처에 종속성이 강한 불필요한 피처는 아예 제거하고, 데이터의 특징을 잘 나타내는 주요 피처만 선택하는 것

피처 추출

- 기존 피처를 저차원의 중요 피처로 압축해서 추출하는 것
- 새롭게 추출된 중요 특성은 기존 피처가 압축된 것이므로 기존의 피처와는 완전히 다른 값이 됨
- 기존 피처를 단순 압축이 아닌, 피처를 함축적으로 더 잘 설명할 수 있는 또 다른 공간으로 매핑해 추출하는 것 → 잠재적인 요소(Latent Factor)를 추출

02. PCA(Principal Component Analysis)

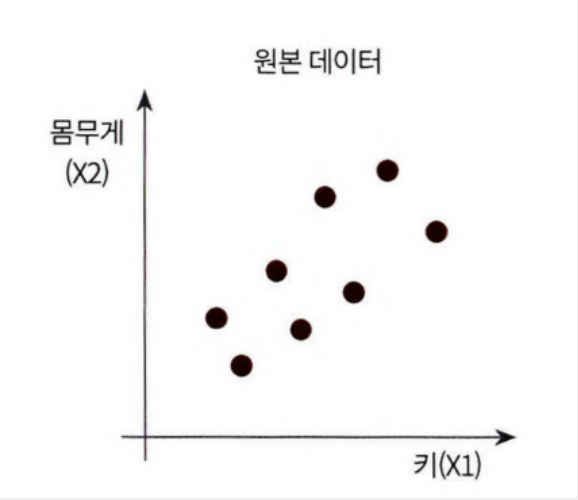
PCA 개요

여러 변수 간에 존재하는 상관관계를 이용해 이를 대표하는 주성분(Principal Component)를 추출해 차원을 축소하는 기법

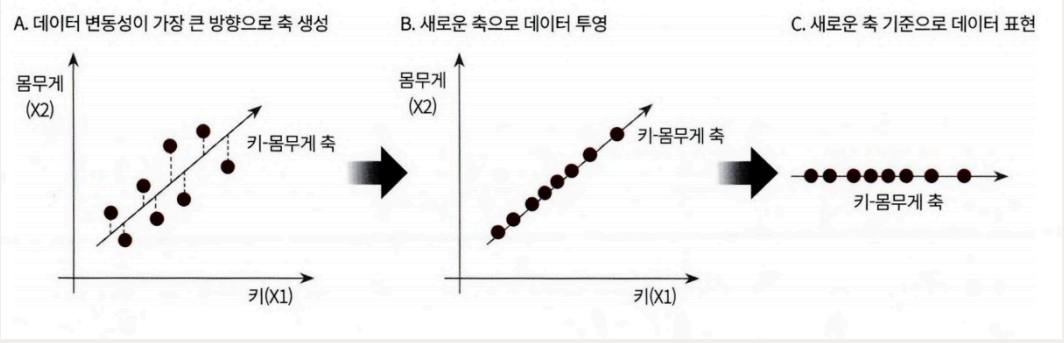
- PCA로 차원을 축소할 때는 기존 데이터의 정보 유실이 최소화 → 가장 높은 분산을 가지는 데이터의 축을 찾아 이 축을 차원으로 축소하는데, 이것이 PCA의 주성분이 됨

💡 PCA란...?

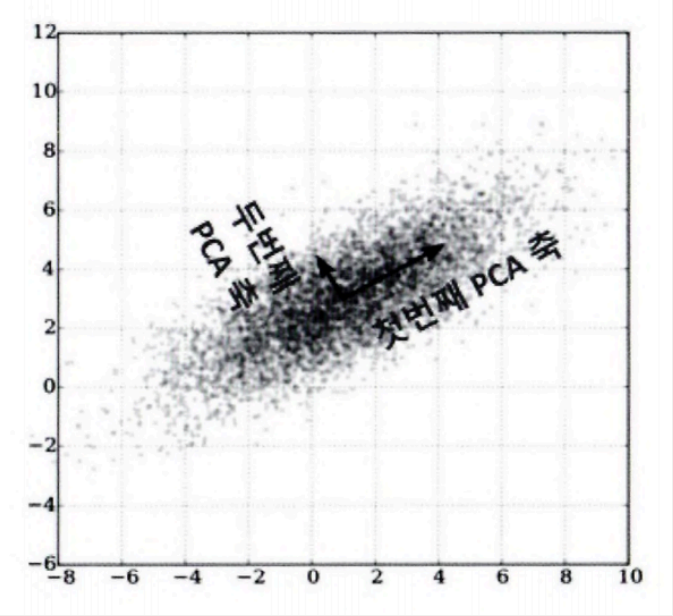
- 예를 들어, 키와 몸무게 2개의 피처를 가지고 있는 데이터 세트가 다음과 같이 구성돼 있음



- 데이터 변동성이 가장 큰 방향으로 축을 생성하고, 새롭게 생성된 축으로 데이터를 투영하는 방식으로 2개의 피처를 한 개의 주성분을 가진 데이터 세트로 차원 축소



- PCA는 제일 먼저 가장 큰 데이터 변동성(Variance)을 기반으로 첫 번째 벡터 축을 생성하고, 두 번째 축은 이 벡터 축에 직각이 되는 벡터를 축으로 함
- 세 번째 축은 다시 두 번째 축과 직각이 되는 벡터를 설정하는 방식으로 축을 생성
- 이렇게 생성된 벡터 축에 원본 데이터를 투영하면 벡터 축의 개수만큼의 차원으로 원본 데이터가 차원 축소됨



- PCA, 즉 주성분 분석은 이처럼 원본 데이터의 피처 개수에 비해 매우 작은 주성분으로 원본 데이터의 총 변동성을 대부분 설명할 수 있는 분석법

PCA를 선형 대수 관점에서 해석해보면,

- 입력 데이터의 공분산 행렬(Convariance Matrix)을 고유값 분해하고, 이렇게 구한 고유벡터에 입력 데이터를 선형 변환하는 것
- 이 고유 벡터가 PCA의 주성분 벡터로서 입력 데이터의 분산이 큰 방향을 나타냄
- 교윳값(eigenvalue)은 바로 이 고유벡터의 크기를 나타내며, 동시에 입력 데이터의 분산을 나타냄

💡 선형 변환이란...?

특정 벡터에 행렬 A를 곱해 새로운 벡터로 변환하는 것을 의미

- 특정 벡터를 하나의 공간에서 다른 공간으로 투영하는 개념으로도 볼 수 있음
- 이 경우 이 행렬을 바로 공간으로 가정하는 것



공분산 행렬이란...?
보통 분산은 한 개의 특정한 변수 데이터 변동을 의미하나, 공분산은 두 변수 간의 변동을 의미

- 사람 키 변수를 X, 몸무게 변수를 Y라고 하면 공분산 Cov(X, Y) > 0 은 X가 증가할 때 Y도 증가한다는 의미

공분산 행렬은 여러 변수와 관련된 공분산을 포함하는 정방형 행렬

	X	Y	Z
X	**3.0**	−0.71	−0.24
Y	−0.71	**4.5**	0.28
Z	−0.24	0.28	**0.91**

- 위 표에서 보면 공분산 행렬에서 대각선 원소는 각 변수의 분산을 의미하며, 대각선 이외의 원소는 가능한 모든 변수 쌍 간의 공분산을 의미

- 고유벡터는 행렬 A를 곱하더라도 방향이 변하지 않고 그 크기만 변하는 벡터를 지칭함
- 이 고유벡터는 여러 개가 존재하며, 정방 행렬은 최대 그 차원 수만큼의 고유벡터를 가질 수 있음.
- 고유벡터는 행렬이 작용하는 힘의 방향과 관계가 있어서 행렬을 분해하는 데에 사용됨

공분산 행렬은 정방행렬(Square Matrix)이며 대칭행렬(Symmetric Matrix)

- 정방행렬은 열과 행이 같은 행렬을 지칭함. 정방행렬 중에서 대각 원소를 중심으로 원소 값이 대칭되는 행렬을 대칭행렬이라고 부름

- 공분산 행렬은 개별 분산값을 대각 원소로 하는 대칭행렬
- 대칭행렬은 항상 고유벡터를 직교행렬(orthogonal matrix)로, 고유값을 정방 행렬로 대각화 할 수 있음

입력 데이터의 공분산 행렬을 C라고 하면 공분산 행렬의 특성으로 인해 다음과 같이 분해할 수 있음

$$C = P \sum P^T$$

위 식은 고유벡터 행렬과 고유값 행렬로 다음과 같이 대응됨

$$C = [e_1 \cdots e_n] \begin{bmatrix} \lambda_1 & \cdots & 0 \\ \cdots & \cdots & \cdots \\ 0 & \cdots & \lambda_n \end{bmatrix} \begin{bmatrix} e_1^t \\ \cdots \\ e_n^t \end{bmatrix}$$

즉, 공분산 C는 고유벡터 직교 행렬 * 고유값 정방 행렬 * 교유벡터 직교 행렬의 전치 행렬로 분해됨

⇒ 입력 데이터의 공분산 행렬이 고유벡터와 고유값으로 분해될 수 있으며, 이렇게 분해된 고유벡터를 이용해 입력 데이터를 선형 변환하는 방식이 PCA

▼ PCA의 단계

1. 입력 데이터 세트의 공분산 행렬을 생성
2. 공분산 행렬의 고유벡터와 고유값을 계산
3. 고유값이 가장 큰 순으로 K개(PCA 변환 차수만큼)만큼 고유벡터를 추출
4. 고유값이 가장 큰 순으로 추출된 고유벡터를 이용해 새롭게 입력 데이터를 변환

03. LDA(Linear Discriminant Analysis)

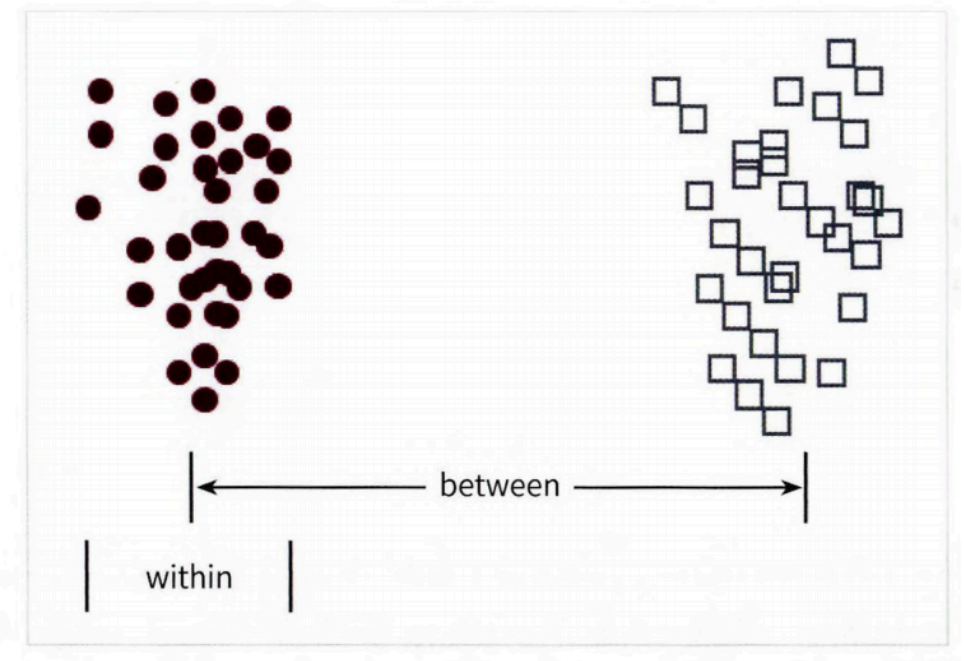
LDA 개요

LDA(Linear Discriminant Analysis)는 선형 판별 분석법으로 불리며, PCA와 매우 유사함

LDA는 PCA와 유사하게 입력 데이터 세트를 저차원 공간에 투영해 차원을 축소하는 기법이지만, 중요한 차이는 LDA는 지도학습의 분류(Classification)에서 사용하기 쉽도록 개별 클래스를 분별할 수 있는 기준을 최대한 유지하면서 차원을 축소함

PCA는 입력 데이터의 변동성의 가장 큰 축을 찾았지만, LDA는 입력 데이터의 결정 값 클래스를 최대한 분리할 수 있는 축을 찾음

LDA는 특정 공간상에서 클래스 분리를 최대화하는 축을 찾기 위해 클래스 간 분산(between-class scatte)과 클래스 내부 분산(within-class scatter)의 비율을 최대화하는 방식으로 차원을 축소 → 클래스 간 분산은 최대한 크게 가져가고, 클래스 내부의 분산은 최대한 적게 가져감



- 일반적으로 LDA를 구하는 스텝은 PCA와 유사하나 가장 큰 차이점은 공분산 행렬이 아니라 위에 설명한 클래스 간 분산과 클래스 내부 분산 행렬을 생성한 뒤, 이 행렬에 기반해 고유벡터를 구하고 입력 데이터를 투영한다는 점

▼ LDA를 구하는 단계

1. 클래스 내부와 클래스 간 분산 행렬을 구함. 이 두 개의 행렬은 입력 데이터의 결정 값 클래스별로 개별 피처의 평균 벡터(mean vector)를 기반으로 구함.
2. 클래스 내부 분산 행렬을 Sw, 클래스간 분산 행렬을 Sb라고 하면 다음 식으로 두 행렬을 고유벡터로 분해할 수 있음
3. 고유값이 가장 큰 순으로 K개(LDA 변환 차수만큼) 추출함
4. 고유값이 가장 큰 순으로 추출된 고유벡터를 이용해 새롭게 입력 데이터를 변환

$$S_W^T S_B = \begin{bmatrix} e_1 & \cdots & e_n \end{bmatrix} \begin{bmatrix} \lambda_1 & \cdots & 0 \\ \cdots & \cdots & \cdots \\ 0 & \cdots & \lambda_n \end{bmatrix} \begin{bmatrix} e_1^T \\ \cdots \\ e_n^T \end{bmatrix}$$

04. SVD(Singular Value Decompostion)

SVD 개요

SVD 역시 PCA와 유사한 행렬 분해 기법을 이용

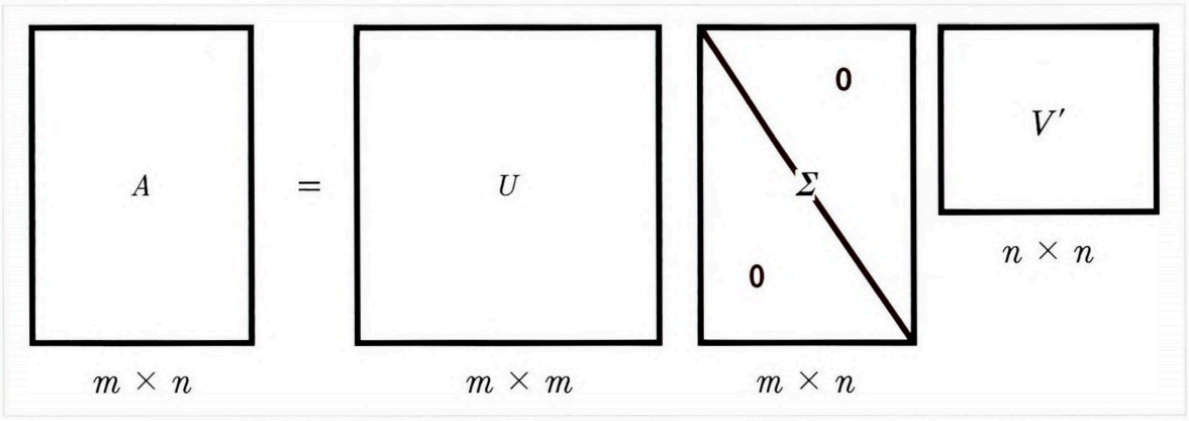
PCA의 경우 정방행렬만을 고유벡터로 분해할 수 있지만, SVD는 정방행렬뿐만 아니라 행과 열의 크기가 다른 행렬에도 적용 가능

일반적으로 SVD는 m x n 크기의 행렬 A를 다음과 같이 분해하는 것을 의미

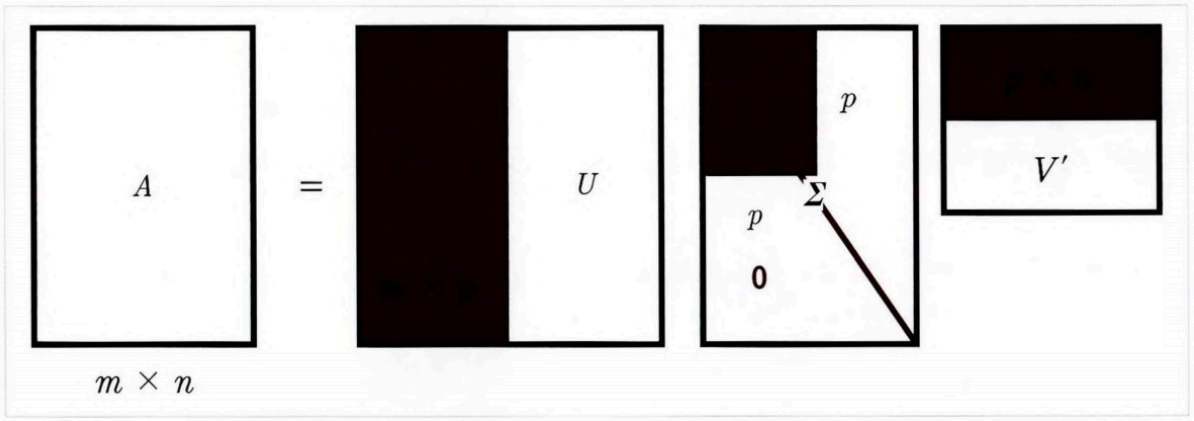
$$A = U \sum V^T$$

- SVD는 특이값 분해로 불리며, 행렬 U와 V에 속한 벡터는 특이벡터이며, 모든 특이 벡터는 서로 직교함

- 시그마는 대각행렬이며, 행렬의 대각에 위치한 값만 0이 아니고 나머지 위치의 값은 모두 0
- 시그마에 위치한 0이 아닌 값이 바로 행렬 A의 특이값



- 일반적으로 다음과 같이 시그마의 비대각인 부분과 대각원소 중에 특이값이 0인 부분도 모두 제거하고 제거된 시그마에 대응되는 U와 V원소도 함께 제거해 차원을 줄인 형태로 SVD를 적용



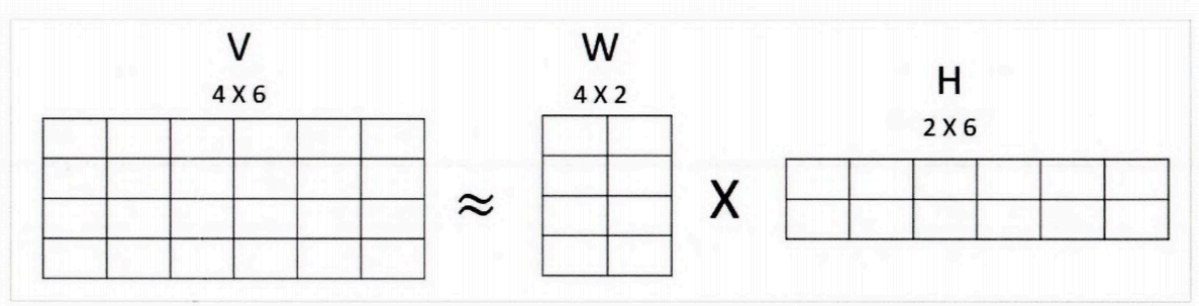
Truncated SVD는 시그마의 대각원소 중에 상위 몇 개만 추출해서 여기에 대응하는 U와 V의 원소도 함께 제거해 더욱 차원을 줄인 형태로 분해하는 것

05. NMF(Non-Negative Matrix Factorization)

NMF 개요

NMF는 Truncated SVD와 같이 낮은 랭크를 통한 행렬 근사(Low-Rank Approximation) 방식의 변형

NMF는 원본 행렬 내의 모든 원소 값이 모두 양수라는 게 보장되면 다음과 같이 좀 더 간단하게 두 개의 기반 양수 행렬로 분해될 수 있는 기법을 지칭함



4 × 6 원본 행렬 V는 4 x 2 행렬 W와 2 x 6 행렬 H로 근사해 분해될 수 있음

행렬 분해(Matrix Factorization)는 일반적으로 SVD와 같은 행렬 분해 기법을 통칭하는 것

- 행렬 분해를 하게되면 W 행렬과 H 행렬은 일반적으로 길고 가는 행렬 W와 작고 넓은 행렬 H로 분해됨
- 분해된 행렬은 잠재 요소를 특성을 갖게 됨
- 분해 행렬 W는 원본 행에 대해서 이 잠재 요소의 값이 얼마나 대응하며, 분해 행렬 H는 이 잠재 요소가 원본 열로 어떻게 구성됐는지를 나타내는 행렬

